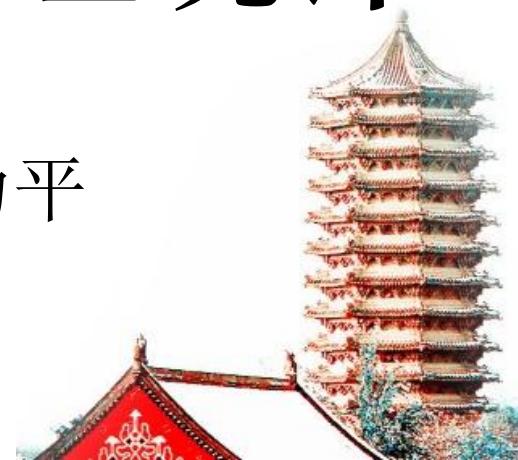




2023-2024春 数理统计

主讲人：数学科学学院 刘力平



第一章 緒論



- 地址: 智华楼335
- 电话: 13681499285
- Email: liping@math.pku.edu.cn

- 助教: 王啸辰: xcwang1998@126.com, 13717689550
杨云帆: 2001110072@pku.edu.cn, 18811058616

- 教材: 陈家鼎等, 《数理统计学讲义》第3版, 高等教育出版社。

第一章 緒論



● 參考書：

1. 陈希孺， 《数理统计引论》， 科学出版社；
2. D. Freedman等（魏宗舒等译）， 《统计学》， 中国统计出版社；
3. Lehmann, «Theory of Point Estimation», John Wiley and Sons;
4. Lehmann, «Testing Statistical Hypothesis», John Wiley and Sons;
5. 陈希孺， 《数理统计学简史》， 湖南教育出版社。

第一章 緒論



- 课堂纪律：学校要求；不影响他人（但强烈建议上课，ppt太少）。
- 平时答疑时间：周二2-4pm。
- 习题：交法（周四课间，可延至周日晚）；分数；标准；
- 与平行课程关系：教学大纲独立，要求独立，各自单独考试，单独改卷，各自评分。
- 考试：20（习题）+20（期中考试，4月？）+60（期末考试）

第一节 数理统计学的研究对象

● 数学分支/一级学科?

● 与数学/概率论的区别: (统计学家一般不参加国际数学家大会)

1. 更明确的背景;
2. “解”的标准不同, 对/错 vs 好/坏;
3. 工作方法不同, 更多计算、模拟等;
4. 思维方式不同。
 - 平均身高比较
 - 充分利用统计正则性
 - 读论语得诺贝尔奖?

第一节 数理统计学的研究对象

- 国际/国内数理统计发展

- 北京大学状况、许宝騏先生

人大等：经济统计；

北大等：数理统计；

流行病学统计等。

- 不要为“容易”学统计

第一节 数理统计学的研究对象

● 本课程特点：

基础课，强调常见背景、基本思想和经典方法的掌握和应用；
不强调逻辑证明；
无软件操作。

● 内容：第二、三、四章大部分，第五章前2节，第七章前2节及扩充；第五章第3节至第七章视情况部分简介。

● 统计正则性

大数律、中心极限定理等

- 掷硬币100次，正面45—55次个数？极强的规律性；
- 重对数率（如掷硬币画图）；
- ……。

第一节 数理统计学的研究对象

● 几个例子：

1. 民意调查：1932年美总统选举，罗斯福vs兰登，文学摘要vs盖洛普。

样本量？抽样方式？Sampling bias。

文学摘要通过超2000万样本预测兰登当选，但预测失败！

因其样本有偏：主要来源于电话号码册与俱乐部名单，多为富人。

第一节 数理统计学的研究对象

2. 孟德尔遗传实验（非常严谨）数据是否存在造假？R. A. Fisher的结论。

数据比例太接近 $3/4: 1/4$ ？

数据分布是客观自然的，自有其分布。

助手之过，凑 $3/4$ ？

3. 商业交易中正品率的判定？

如何根据部分样品判断本批商品的次品率不超标。

第一节 数理统计学的研究对象

4. 铝厂非法罢工后，资方发现，因停电，某元件的寿命缩短，诉工会赔偿损失。

该赔多少？

法庭上双方均聘请统计学家辩论……

某统计期刊邀请全球统计学家探讨。

第二节 数理统计学的基本概念

- 总体和个体：用分布函数 $F(\cdot)$ ，或随机变量（向量） X 表示总体。
- 样本：被抽取到的个体，用 X_1, \dots, X_n 或 x_1, \dots, x_n 表示，称 n 为样本量；
习惯上大小写的区别。
若假设独立同分布（iid），称简单随机样本。
- 统计量：样本的（可测）函数 $g(x_1, \dots, x_n)$ 。
- 其他的，逐步介绍。

第三节 数理统计学发展简史

请自己阅读。

详细内容请见陈希孺的《数理统计学简史》。

第二章 估计



第一节 参数估计的方法

背景：我们已知总体的分布类型，但不知其中的参数值，希望由数据对参数给出估计。如长期实践中得知，轴承寿命服从Weibull分布，但各种厂家、型号的参数不同。

例如， X 是收入，随机抽取样本 x_1, \dots, x_n ，设近似服从 $N(\mu, \sigma^2)$ ，则 $\theta = (\mu, \sigma^2)$ ， $\Theta \subset R^2$ 为上半平面。我们的兴趣为：① 平均收入，则 $g_1(\theta) = \mu$ ；② 贫富分化程度，则 $g_2(\theta) = \sigma^2$ ；③ 贫困人口比例，则 $g_3(\theta) = P(X < C) = P\left(\frac{X-\mu}{\sigma} < \frac{C-\mu}{\sigma}\right) = \Phi\left(\frac{C-\mu}{\sigma}\right)$ ，其中 C 为贫困线。

数学表述： X 的分布函数为 $F(x, \theta)$ ，密度函数（或概率函数）为 $f(x, \theta)$ ，其中 $\theta = (\theta_1, \dots, \theta_m) \in \Theta \subset R^m$ ， f 的形式已知，问题为通过样本 x_1, \dots, x_n 估计目标 $g(\theta)$ 。

第一节 参数估计的方法



一、最大似然估计法 (Maximum Likelihood Estimate, 简记为MLE)

● 似然函数：称

$$L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i, \theta)$$

为参数 θ 的，关于样本 x_1, \dots, x_n 的似然函数。

概率论中， θ 不变， x_1, \dots, x_n 是变元，称联合分布；

数理统计中， x_1, \dots, x_n 已知（不变）， θ 未知，是函数变元。

● 称似然函数的（一个）最大值点（若存在） $\hat{\theta}_n = \hat{\theta} = \varphi(x_1, \dots, x_n)$ 为 θ 的最大似然估计。

第一节 参数估计的方法



一、最大似然估计法 (Maximum Likelihood Estimate, 简记为MLE)

● 似然函数：称

$$L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i, \theta)$$

为参数 θ 的，关于样本 x_1, \dots, x_n 的似然函数。

概率论中， θ 不变， x_1, \dots, x_n 是变元，称联合分布；

数理统计中， x_1, \dots, x_n 已知（不变）， θ 未知，是函数变元。

● 称似然函数的（一个）最大值点（若存在） $\hat{\theta}_n = \hat{\theta} = \varphi(x_1, \dots, x_n)$ 为 θ 的最大似然估计。

第一节 参数估计的方法



- 经典统计中最重要的估计方法，首先想到。
- 具有许多好的性质，某些标准下最优。
- 思想：用最可能（most likely）产生数据的参数值作为估计值。

例如：射击10枪，7中， X_1, \dots, X_{10} 独立同分布，共同分布为 $B(1, p)$ 。若只许你猜 p 为 0.2 或 0.8，如何猜；若允许你在 $(0, 1)$ 中猜，如何猜？

- 求解方法：一般为数学上求最大值方法，取对数（乘积式变为和式），求导，令其等于0。
- 如解不唯一，任何一个均为MLE。

第一节 参数估计的方法



- 强相合性 (strong consistency) :

$$P\left(\lim_{n \rightarrow \infty} \hat{\theta}_n = \theta\right) = 1 \quad (\text{实变中的几乎处处收敛})$$

- (弱) 相合性 (consistency) : $\forall \varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P\left(\|\hat{\theta}_n - \theta\| < \varepsilon\right) = 1 \quad (\text{实变中的依测度收敛})$$

- 理论上，强相合性可推出弱相合性，反之不成立。应用中，一般无区别（一般说相合性，指的是弱相合性）。

- 直观意义：随样本量增大，估计值可任意接近目标。

- 区别原因：随机变量的收敛比一般收敛复杂。

第一节 参数估计的方法

几种常见分布：

1. 两点 (Bernoulli) 分布, $X_i \sim B(1, p)$, x_1, \dots, x_n 为数据, 取值 0、1,

$$\begin{aligned} P(X_i = x_i) &= p^{x_i}(1-p)^{1-x_i} \\ L(x_1, \dots, x_n, p) &= \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} \\ &= p^{\sum_{i=1}^n x_i}(1-p)^{n-\sum_{i=1}^n x_i} \end{aligned}$$

$$\log(L(p)) = \sum_{i=1}^n x_i \log(p) + (n - \sum_{i=1}^n x_i) \log(1-p)$$

$$\frac{\partial \log(L(p))}{\partial p} = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0$$

唯一解为 $\hat{p} = \hat{p}_n = \frac{1}{n} \sum_{i=1}^n x_i = : \bar{x} = \frac{v}{n}$, 概率论中常说的频率。

相合性：由强大数律， $\lim_{n \rightarrow \infty} \hat{p}_n = p$ (a.s.), 即频率 \rightarrow 概率。

第一节 参数估计的方法

2. 指数分布, $X_i \sim Exp(\lambda)$,

$$p(x) = \lambda e^{-\lambda x} \quad (\text{当 } x > 0)$$

$$L(\lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

$$\log(L(\lambda)) = n \log \lambda - \lambda \sum_{i=1}^n x_i$$

$$\frac{\partial \log(L(\lambda))}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i$$

唯一解为 $\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i} = 1/\bar{x}$ 。

相合性: $\bar{x} \rightarrow E(X) = 1/\lambda$, 故 $\hat{\lambda} \rightarrow \lambda$ (a.s.)

$1/\lambda$ 的直观意义: 平均寿命。

第一节 参数估计的方法

3. 正态分布, $X_i \sim N(\mu, \sigma^2)$, 令 $\delta = \sigma^2$,

$$L(\mu, \delta) = \left(\frac{1}{\sqrt{2\pi\delta}} \right)^n e^{-\frac{1}{2\delta} \sum_{i=1}^n (x_i - \mu)^2}$$
$$\log(L(\mu, \delta)) = n \log(C) - \frac{n}{2} \log(\delta) - \frac{1}{2\delta} \sum_{i=1}^n (x_i - \mu)^2$$

其中 C 为某常数,

似然方程组为:

$$\begin{cases} \frac{\partial \log L}{\partial \mu} = \frac{1}{\delta} \sum_{i=1}^n (x_i - \mu) = 0 \\ \frac{\partial \log L}{\partial \delta} = -\frac{n}{2\delta} + \frac{1}{2\delta^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \end{cases}$$

唯一解为:

$$\begin{cases} \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} & \text{(样本均值)} \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{cases}$$

第一节 参数估计的方法

相合性：

由大数率， $P\left(\lim_{n \rightarrow \infty} \hat{\mu} = \mu\right) = 1;$

又由 $P\left(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i^2 = EX^2\right) = 1,$

故而

$P\left(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n x_i^2 - \lim_{n \rightarrow \infty} \hat{\mu}^2 = EX^2 - (EX)^2\right) = 1,$

即 $P\left(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = var(X)\right) = 1,$

即 $P\left(\lim_{n \rightarrow \infty} \hat{\delta} = \delta\right) = 1.$

注意其中有： $\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - \frac{1}{n} (\sum_{i=1}^n X_i)^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$
这个常用等式。

第一节 参数估计的方法

4. 威布尔 (Weibull) 分布

$$F(x, m, \eta) = 1 - \exp\left(-\left(\frac{x}{\eta}\right)^m\right) \quad (\text{当 } x > 0, \text{ 参数 } m > 0, \eta > 0。)$$

$$\Rightarrow f(x, m, \eta) = \frac{m}{\eta^m} x^{m-1} e^{-\left(\frac{x}{\eta}\right)^m}$$

故 $L(m, \eta) = \frac{m^n}{\eta^{mn}} \left(\prod_{i=1}^n x_i \right)^{m-1} e^{-\frac{\sum_{i=1}^n x_i^m}{\eta^m}}$

取对数，求偏导，可得似然方程组。计算机求解。

无显式解，如何证明相合性？

第一节 参数估计的方法

5. 均匀分布 $X \sim U[a, b]$ (或简化版本 $X \sim U[0, \theta]$)

$$f(x, a, b) = \begin{cases} \frac{1}{b-a} & \text{若 } a \leq x \leq b \\ 0 & \text{否则} \end{cases}$$

$$L(a, b) = \left(\frac{1}{b-a}\right)^n \prod_{i=1}^n I_{[a, b]}(x_i),$$

$$\text{所以 } L(a, b) = \begin{cases} \left(\frac{1}{b-a}\right)^n & \text{当 } a \leq \min_{1 \leq i \leq n} x_i \text{ 且 } b \geq \max_{1 \leq i \leq n} x_i \\ 0 & \text{否则} \end{cases}$$

故 $\hat{a} = \min_{1 \leq i \leq n} x_i$, $\hat{b} = \max_{1 \leq i \leq n} x_i$ (不连续, 不可导)。

相合性: 教材中有证明, 用到实变函数方法。

第一节 参数估计的方法

二、矩估计法 (Moment Estimate)

设 $\theta = (\theta_1, \dots, \theta_m)$, X 的 k 阶矩存在有限, (理论) 值为

$$\begin{cases} V_1 = E(X^1) = g_1(\theta_1, \dots, \theta_m) \\ \dots \quad \dots \\ V_m = E(X^m) = g_m(\theta_1, \dots, \theta_m) \end{cases}$$

样本矩为

$$\begin{cases} \tilde{V}_1 = \frac{1}{n} \sum_{i=1}^n x_i \\ \dots \quad \dots \\ \tilde{V}_m = \frac{1}{n} \sum_{i=1}^n x_i^m \end{cases}$$

由大数律 (一定条件下), $\tilde{V}_k \rightarrow V_k$ (当样本量 $\rightarrow \infty$), 令其相等, 得到估计方程组

第一节 参数估计的方法



$$\begin{cases} g_1(\theta_1, \dots, \theta_m) = \tilde{V}_1 \\ \dots \quad \dots \\ g_m(\theta_1, \dots, \theta_m) = \tilde{V}_m \end{cases}$$

若解为

$$\begin{cases} \tilde{\theta}_1 = f_1(\tilde{V}_1, \dots, \tilde{V}_m) \\ \dots \quad \dots \\ \tilde{\theta}_m = f_m(\tilde{V}_1, \dots, \tilde{V}_m) \end{cases}$$

则称其为 $(\theta_1, \dots, \theta_m)$ 的矩估计。（存在性、唯一性）

矩估计历史上曾有重要地位（Pearson），后Fisher力推MLE。

有时MLE收敛速度更快。

第一节 参数估计的方法

几种常见分布：

1. 两点 (Bernoulli) 分布, $X_i \sim B(1, p)$,

此时 $m = 1$, 而 $V_1 = EX = p$, $\tilde{V}_1 = \bar{x}$, 故 $\tilde{p} = \bar{x}$, 与MLE相同。

2. 指数分布, $X_i \sim Exp(\lambda)$,

此时 $V_1 = EX = 1/\lambda$, $\tilde{V}_1 = \bar{x}$, 故 $\tilde{\lambda} = 1/\bar{x}$, 与MLE一致。

3. 正态分布, $X_i \sim N(\mu, \sigma^2)$

此时 $m = 2$, $V_1 = EX = \mu$, $\tilde{V}_1 = \bar{x}$,

$$V_2 = EX^2 = \sigma^2 + \mu^2, \quad \tilde{V}_2 = \frac{1}{n} \sum_{i=1}^n x_i^2,$$

第一节 参数估计的方法

解方程易知， $(\tilde{\mu}, \tilde{\sigma}^2)$ 与MLE相同。

4. 威布尔 (Weibull) 分布

$$V_1 = EX = \eta \Gamma\left(\frac{1}{m} + 1\right), \quad V_2 = \eta^2 \Gamma\left(\frac{2}{m} + 1\right),$$

故估计方程为：

$$\begin{cases} \eta \Gamma\left(\frac{1}{m} + 1\right) = \frac{1}{n} \sum_{i=1}^n x_i \\ \eta^2 \Gamma\left(\frac{2}{m} + 1\right) = \frac{1}{n} \sum_{i=1}^n x_i^2 \end{cases}$$

与MLE不同。

第一节 参数估计的方法

5. 均匀分布 $X \sim U[0, \theta]$

此时 $m = 1$, 令 $EX = \frac{\theta}{2} = \bar{x}$, 得 $\tilde{\theta} = 2\bar{x}$,

与MLE ($\hat{\theta} = \max_{1 \leq i \leq n} x_i$) 不同。

哪个好, 或各自优缺点?

- MLE ($\max_{1 \leq i \leq n} x_i$) 概率为1地偏小。
- 矩估计在明知对某个 $i \leq n$, $\theta \geq x_i$ (x_i 较大) 时, 会仍用偏小的 $2\bar{x}$ 作为估计。

第一节 参数估计的方法

三、一个实例

例1. “序列号” 估计方法（背景：二战）

模型为 N 未知，从 $\{1, 2, \dots, N\}$ 中随机抽取 n 个，记为 $\{0 < k_1 < \dots < k_n \leq N\}$ ，希望利用此数据估计 N 。

首先可以用 $\frac{1}{n-1} \sum_{i=2}^n (k_i - k_{i-1} - 1)$ 对两个数据间的平均间隔进行估计，从而 N 的一个自然的估计为：

$$\begin{aligned}\widehat{W}_1 &= k_n + \frac{1}{n-1} \sum_{i=2}^n (k_i - k_{i-1} - 1) \\ &= k_n + \frac{1}{n-1} (k_n - k_1) - 1 = \frac{n}{n-1} k_n - \frac{1}{n-1} k_1 - 1\end{aligned}$$

可以证明， $E(\widehat{W}_1) = N$ 。

第一节 参数估计的方法

郑忠国提出了改进的估计：

$$\begin{aligned}\widehat{W}_2 &= k_n + \frac{1}{n} \sum_{i=1}^n (k_i - k_{i-1} - 1) \\ &= \frac{n+1}{n} k_n - 1\end{aligned}$$

其中 $k_0 = 0$ 。亦可证明， $E(\widehat{W}_2) = N$ ，但其方差更小。

期望、方差表示什么？概率空间如何定义？

离散型均匀分布。

第二节 估计的优良性标准

当用 $\varphi(x_1, \dots, x_n)$ 估计目标 $g(\theta)$ 时，希望 $\varphi(x_1, \dots, x_n)$ 与目标 $g(\theta)$ 距离越近越好。但因为 $\varphi(x_1, \dots, x_n)$ 是随机变量， $g(\theta)$ 是 θ 的函数，也可以取不同的值，所以如何定义“距离”很重要。

在数理统计中，对同一随机事件，当参数 θ 取不同的值时，对应的概率测度也不同。为明确起见，记可测空间 (Ω, \mathcal{F}) 上的概率分布族为 $\{P_\theta, \theta \in \Theta\}$ ，记相应的期望、方差等为 $E_\theta()$ 、 $Var_\theta()$ 等。

定义1. 称 $\varphi(X_1, \dots, X_n)$ 为 $g(\theta)$ 的无偏估计，若

$$E_\theta \varphi(X_1, \dots, X_n) = g(\theta), \quad \forall \theta \in \Theta$$

这是较正常的要求。

第一节的常用分布中，两点分布 p 的MLE、正态分布中 μ 的MLE等都是无偏的，均匀分布的矩估计也是，但正态分布中 σ^2 的MLE不是无偏的！

第二节 估计的优良性标准



定义2. 设 $\varphi(X_1, \dots, X_n)$ 为 $g(\theta)$ 的一个估计，称

$$M_\theta(\varphi) = E_\theta[\varphi(X_1, \dots, X_n) - g(\theta)]^2$$

为 φ 的均方误差 (Mean square error, MSE)。

若 φ 是无偏的，则 $M_\theta(\varphi) = Var_\theta(\varphi)$ 。

定义3. 对于 $g(\theta)$ 的两个估计 φ_1, φ_2 ，若 $\forall \theta \in \Theta$ ，有 $M_\theta(\varphi_1) \leq M_\theta(\varphi_2)$ ，则称 φ_1 不次于 φ_2 ；若还存在 $\theta_0 \in \Theta$ ，使得 $M_{\theta_0}(\varphi_1) < M_{\theta_0}(\varphi_2)$ ，则称 φ_1 比 φ_2 有效。

例如，若 X 的方差存在有限， θ 是 X 的均值，令 $\varphi_1(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n X_i$ ， $\varphi_2(X_1, \dots, X_n) = \sum_{i=1}^n \lambda_i X_i$ ，其中 λ_i 满足 $\sum_{i=1}^n \lambda_i = 1$ ，则 φ_1, φ_2 均无偏； φ_1 不次于 φ_2 ；若 λ_i 不全相等，则 φ_1 比 φ_2 有效。

第二节 估计的优良性标准

●两个估计并不一定总能比较！一般地，不能找到不次于所有其他估计的估计量。（？）例如用常数 $\varphi(X_1, \dots, X_n) \equiv g(\theta_0)$ 估计 $g(\theta) \dots$ 。

●缩小范围，仅考虑无偏估计。

定义4. 称 $\varphi(X_1, \dots, X_n)$ 为 $g(\theta)$ 的（一致）最小方差无偏估计（MVUE），如果它无偏，且对任意的 $g(\theta)$ 的无偏估计 $\psi(X_1, \dots, X_n)$ ，有 $M_\theta(\varphi) \leq M_\theta(\psi)$ （对 $\forall \theta \in \Theta$ ）。(φ : \phi; ψ : \psi)

●最小方差无偏估计在许多常见情形下存在唯一，并可以求出。

●是一定标准下的“最优良”的估计。还有其他标准。

●如何求？可以通过利用充分统计量。

第二节 估计的优良性标准

定义5. 设 X_1, \dots, X_n 为简单随机样本，称统计量 $U = \varphi(X_1, \dots, X_n)$ 是 θ 的充分 (sufficient) 统计量，若似然函数 $L(x_1, \dots, x_n, \theta)$ 可表示为

$$q[\varphi(x_1, \dots, x_n), \theta] \cdot h(x_1, \dots, x_n)$$

其中 $h(x_1, \dots, x_n)$ 是不依赖于 θ 的非负函数。

●直观意义：充分统计量包含了样本 X_1, \dots, X_n 中关于参数 θ 的全部信息。

● $\varphi_0(X_1, \dots, X_n) = (X_1, \dots, X_n)$ 一定是 θ 的充分统计量。

●引入定义5的目的：降低样本的维数及复杂度时，不丢失关于 θ 的信息。

●等价表示：给定 u_0 及可测集 A ， $P_\theta((X_1, \dots, X_n) \in A | U = u_0)$ 与 θ 无关。

-----end 2024.02.22

有了充分统计量 U ，构造 $g(\theta)$ 的估计时，可以仅考虑利用 U 即可。易知 U 的维数越低越好。

第二节 估计的优良性标准

定义5. 设 X_1, \dots, X_n 为简单随机样本，称统计量 $U = \varphi(X_1, \dots, X_n)$ 是 θ 的充分 (sufficient) 统计量，若似然函数 $L(x_1, \dots, x_n, \theta)$ 可表示为

$$q[\varphi(x_1, \dots, x_n), \theta] \cdot h(x_1, \dots, x_n)$$

其中 $h(x_1, \dots, x_n)$ 是不依赖于 θ 的非负函数。

●直观意义：充分统计量包含了样本 X_1, \dots, X_n 中关于参数 θ 的全部信息。

● $\varphi_0(X_1, \dots, X_n) = (X_1, \dots, X_n)$ 一定是 θ 的充分统计量。

●引入定义5的目的：降低样本（函数）的维数及复杂度时，不丢失关于 θ 的信息。

●等价表示：给定 u_0 及可测集 A ， $P_\theta((X_1, \dots, X_n) \in A | U = u_0)$ 与 θ 无关。

有了充分统计量 U ，构造 $g(\theta)$ 的估计时，可以仅考虑利用 U 即可。易知 U 的维数越低越好。

第二节 估计的优良性标准

几个例子：

1. 两点分布

$$\begin{aligned}L(x_1, \dots, x_n, p) &= p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} \\&= (1-p)^n \left(\frac{p}{1-p}\right)^{\sum_{i=1}^n x_i} \cdot 1\end{aligned}$$

即 $\sum_{i=1}^n X_i$ 与 p 的函数乘 1，所以 $\varphi(X_1, \dots, X_n) = \sum_{i=1}^n X_i$ 是 p 的充分统计量。

(n 次射击后，欲估计射击命中率，仅需知道总击中次数，不需知道具体结果。)

对任意 $1 \leq k < n$ ， $(\sum_{i=1}^k x_i, \sum_{i=k+1}^n x_i)$ 也是充分统计量。

2. 指数分布

$$L(x_1, \dots, x_n, \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

所以 $\sum_{i=1}^n X_i$ 是 λ 的充分统计量。同理， $(\sum_{i=1}^k x_i, \sum_{i=k+1}^n x_i)$ 也是。

第二节 估计的优良性标准

3. 正态分布

$$\begin{aligned} L(x_1, \dots, x_n, \mu, \delta) &= \left(\frac{1}{\sqrt{2\pi}\delta}\right)^n e^{-\frac{1}{2\delta}\sum_{i=1}^n(x_i-\mu)^2} \\ &= (2\pi\delta)^{-\frac{n}{2}} e^{\left\{-\frac{1}{2\delta}\left[\sum_{i=1}^n(x_i-\bar{x})^2+n(\bar{x}-\mu)^2\right]\right\}} \end{aligned}$$

故 $\varphi(X_1, \dots, X_n) = (\bar{X}, \sum_{i=1}^n (X_i - \bar{X})^2)$ 是 (μ, δ) 的充分统计量。

定义6. 若存在（非负可测）函数 $h(x)$ 、 $S(\theta)$ ，正整数 k ，及 $C_j(\theta)$ ， $T_j(x)$ ($1 \leq j \leq k$)，使随机变量 X 的密度函数（或概率函数）可表示为

$$f(x, \theta) = S(\theta)h(x) \exp\left\{\sum_{j=1}^k C_j(\theta)T_j(x)\right\}$$

则称其服从指类型分布（或称指数分布族）。

- 它包括许多常用分布，如两点分布、二项分布、指数分布、正态分布、Poisson分布等。可同时研究。 k 一般不大。

第二节 估计的优良性标准

●因为相乘即指数相加，所以

$$L(\theta) = S(\theta)^n \cdot \prod_{i=1}^n h(x_i) \cdot \exp \left\{ \sum_{j=1}^k C_j(\theta) \sum_{i=1}^n T_j(x_i) \right\}$$

故而($\sum_{i=1}^n T_1(x_i)$, \dots , $\sum_{i=1}^n T_k(x_i)$)是 θ 的一个充分统计量。

4. 均匀分布（不属于指数分布族）

$$L(a, b) = \left(\frac{1}{b-a} \right)^n I_{[a, \infty)}(\min_{1 \leq i \leq n} x_i) I_{(-\infty, b]}(\max_{1 \leq i \leq n} x_i)$$

故($\min_{1 \leq i \leq n} x_i$, $\max_{1 \leq i \leq n} x_i$)是(a, b)的充分统计量。

定义7. 称统计量 $U = \varphi(X_1, \dots, X_n)$ 是 θ 的完全 (complete) 统计量，若任给 (可测) 函数 $u(\cdot)$ ，如果

$$E_\theta\{u(\varphi(X_1, \dots, X_n))\} = 0 \quad (\forall \theta \in \Theta)$$

则有 $P_\theta(u(\varphi(X_1, \dots, X_n))) = 0\} = 1$ ，对 $\forall \theta \in \Theta$ 。

第二节 估计的优良性标准

●两点分布中， $\varphi(X_1, \dots, X_n) = \sum_{i=1}^n X_i$ 是完全的：

对任意 $u(\cdot)$ ，因为 $\varphi(X_1, \dots, X_n) \sim B(n, p)$ ，如果

$$E_p u(\varphi) = 0 \quad \forall p \in (0, 1)$$

则 $\sum_{k=0}^n C_n^k p^k (1-p)^{n-k} u(k) = 0$ ，对 $\forall p \in (0, 1)$ 。

记 $y = p/(1-p)$ ，则 $\sum_{k=0}^n u(k) C_n^k y^k = 0$ ，对 $\forall y \in (0, \infty)$ ，

故有 $u(k) = 0$ ，($k = 0, \dots, n$)，即 φ 是完全的。

●两点分布中， $\tilde{\varphi}(X_1, \dots, X_n) = (\varphi_1, \varphi_2) = (\sum_{i=1}^k X_i, \sum_{i=k+1}^n X_i)$ 不是完全的 ($\forall 1 \leq k < n$)：

令 $u(\tilde{\varphi}) = u(\varphi_1, \varphi_2) = \frac{\varphi_1}{k} - \frac{\varphi_2}{n-k}$ ，则 $E_p u(\tilde{\varphi}) = 0$ ，但 $u(\tilde{\varphi}) \not\equiv 0$ 。

●两点分布中， $\varphi(X_1, \dots, X_n) = (X_1, \dots, X_n)$ 是充分的，不是完全的。

第二节 估计的优良性标准

●数据压缩（降维）或数据预处理的优良性标准：

- ① 该保留的信息都保留—充分性；
- ② 该丢掉的信息都丢掉—完全性。

两点分布中， (X_1, \dots, X_n) 、 $(\sum_{i=1}^k X_i, \sum_{i=k+1}^n X_i)$ 、 $\sum_{i=1}^n X_i$ 都是充分的，但仅 $\sum_{i=1}^n X_i$ 是完全的。

●可以证明，若参数空间 Θ 有内点，则指数分布族中的充分统计量 $(\sum_{i=1}^n T_1(x_i), \dots, \sum_{i=1}^n T_k(x_i))$ 是完全的。

定理 (Blackwell-Lehmann-Scheffe) 若 $\varphi(X_1, \dots, X_n)$ 是 θ 的完全的充分统计量， $\psi(\varphi(X_1, \dots, X_n))$ 是 $g(\theta)$ 的无偏估计，则它就是 $g(\theta)$ 的（一致）最小方差无偏估计，且在概率为1相等的意义下，是唯一的。

●定理非常重要。

●定理说明，最小方差无偏估计仅需通过完全的充分统计量构造。

第二节 估计的优良性标准

对于正态分布， $(\bar{X}, \sum_{i=1}^n (X_i - \bar{X})^2)$ 是完全的充分统计量，故而，

因为 $E\bar{X} = \mu$ ，所以 \bar{X} 就是 μ 的最小方差无偏估计；

令 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ （称为样本方差），则

$$\begin{aligned} E(S^2) &= E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i^2 - n\bar{X}^2)\right] \\ &= \frac{1}{n-1} \sum_{i=1}^n E(X_i^2) - \frac{n}{n-1} E(\bar{X}^2) \\ &= \frac{n}{n-1} (\sigma^2 + \mu^2) - \frac{n}{n-1} (Var(\bar{X}) + (E\bar{X})^2) \\ &= \frac{n}{n-1} \sigma^2 + \frac{n}{n-1} \mu^2 - \frac{n}{n-1} \left(\frac{\sigma^2}{n} + \mu^2\right) \\ &= \sigma^2 \end{aligned}$$

故 S^2 是 σ^2 的最小方差无偏估计。注意其MLE和矩估计均为 $\frac{n-1}{n} S^2$ 。

第二节 估计的优良性标准

- 无偏估计有时不存在：例如，两点分布中，因为对任意的估计 ψ ,

$$E_p(\psi(X_1, \dots, X_n)) = \sum_{x_i=0,1} \psi(x_1, \dots, x_n) p^{x_i} (1-p)^{1-x_i}$$

是 p 的（最高 n 次）多项式，故而当 $g(p)$ 为有理函数时，不存在其无偏估计，故也不存在其最小方差无偏估计。见P27例2.5（其中有具体的 $g(p) = \frac{1}{1+p^2}$ ）。

- 无偏估计有时虽然存在，但不合理（例如P27例2.6）：设 X 服从Poisson分布，参数为 θ ，样本量为1，而 $g(\theta) = e^{-2\theta}$ 。可以证明， $g(\theta)$ 的唯一的无偏估计为

$$\hat{g}(X) = (-1)^X$$

即当 X 为偶数时，用1估计 $g(\theta)$ ；而当 X 为奇数时，用-1估计 $g(\theta)$ 。但我们已知 $g(\theta) = e^{-2\theta} > 0$ ，所以此例中，坚持无偏性不合理。

第二节 估计的优良性标准

- 从一般的统计应用中看，上页的**有时**并不特别常见（上面两个例子显然都是人造的）。许多情况下，无偏性是较自然、合理的要求。（数学思维 vs 统计思维）
- 结合大样本性质，还有“渐近无偏”的概念。
- 最小方差无偏估计的方差有多小？下面是一个非常重要的定理。

第二节 估计的优良性标准

定理 (Cramer-Rao不等式) : 设 X 的密度函数为 $f(x, \theta)$, $\theta \in (a, b)$, ($-\infty \leq a < b \leq \infty$), (X_1, \dots, X_n) 是 X 的简单随机样本, $\varphi(X_1, \dots, X_n)$ 是 $g(\theta)$ 的无偏估计, 则在下列条件下,

(1) X 的支撑 $E = \{x: f(x, \theta) > 0\}$ 与 θ 无关;

(2) $g'(\theta)$ 与 $\frac{\partial f(x, \theta)}{\partial \theta}$ 都存在, 且

$$\begin{aligned} \int_E \frac{\partial f(x, \theta)}{\partial \theta} dx &= \frac{\partial}{\partial \theta} \left(\int_E f(x, \theta) dx \right) = 0 \\ \frac{\partial}{\partial \theta} \int_E \cdots \int_E \varphi(x_1, \dots, x_n) \prod_{i=1}^n f(x_i, \theta) dx_1 \cdots dx_n \\ &= \int_E \cdots \int_E \varphi(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \prod_{i=1}^n f(x_i, \theta) dx_1 \cdots dx_n \end{aligned}$$

有不等式

$$var_{\theta}(\varphi(X_1, \dots, X_n)) \geq \frac{(g'(\theta))^2}{nI(\theta)} \quad \forall \theta \in \Theta$$

其中 $I(\theta) = \int_E \left(\frac{\partial \log f(x, \theta)}{\partial \theta} \right)^2 f(x, \theta) dx = E_{\theta} \left(\frac{\partial \log f(x, \theta)}{\partial \theta} \right)^2 > 0$ 称为 θ 的Fisher信息量。

第二节 估计的优良性标准

证明：不妨设 $\text{var}_\theta(\varphi(X_1, \dots, X_n)) < \infty$ ，且 $I(\theta) < \infty$ 。因为

$$\begin{aligned}\frac{\partial}{\partial \theta} \prod_{i=1}^n f(x_i, \theta) &= \sum_{j=1}^n \left[\prod_{i \neq j} f(x_i, \theta) \frac{\partial f(x_j, \theta)}{\partial \theta} \right] \\ &= \sum_{j=1}^n \left[\prod_{i=1}^n f(x_i, \theta) \frac{\frac{\partial f(x_j, \theta)}{\partial \theta}}{f(x_j, \theta)} \right] \\ &= \prod_{i=1}^n f(x_i, \theta) \sum_{i=1}^n \frac{\partial}{\partial \theta} [\log f(x_i, \theta)]\end{aligned}$$

而

$$g(\theta) = \int_E \cdots \int_E \varphi(x_1, \dots, x_n) \prod_{i=1}^n f(x_i, \theta) dx_1 \cdots dx_n$$

(因是无偏估计)

第二节 估计的优良性标准

所以

$$\begin{aligned} g'(\theta) &= \int_E \cdots \int_E \varphi(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \prod_{i=1}^n f(x_i, \theta) dx_1 \cdots dx_n \\ &= \int_E \cdots \int_E \varphi(x_1, \dots, x_n) \sum_{i=1}^n \frac{\partial}{\partial \theta} [\log f(x_i, \theta)] \prod_{i=1}^n f(x_i, \theta) dx_1 \cdots dx_n \\ &= E_\theta \left[\varphi(X_1, \dots, X_n) \sum_{i=1}^n \frac{\partial}{\partial \theta} [\log f(X_i, \theta)] \right] \end{aligned}$$

又因为

$$\begin{aligned} E_\theta \left\{ \sum_{i=1}^n \frac{\partial}{\partial \theta} [\log f(X_i, \theta)] \right\} &= n E_\theta \left[\frac{\partial}{\partial \theta} [\log f(X_1, \theta)] \right] \\ &= n \int_E \frac{\partial f(x, \theta)}{\partial \theta} dx = 0 \end{aligned}$$

所以 $g'(\theta) = E_\theta \left[(\varphi(X_1, \dots, X_n) - g(\theta)) \sum_{i=1}^n \frac{\partial}{\partial \theta} [\log f(X_i, \theta)] \right]$

第二节 估计的优良性标准

故

$$\begin{aligned}[g'(\theta)]^2 &\leq E_{\theta}[(\varphi(X_1, \dots, X_n) - g(\theta))]^2 E_{\theta}\left[\sum_{i=1}^n \frac{\partial}{\partial \theta} [\log f(X_i, \theta)]\right]^2 \\&= var_{\theta}(\varphi) var_{\theta}\left(\sum_{i=1}^n \frac{\partial}{\partial \theta} [\log f(X_i, \theta)]\right) \\&= var_{\theta}(\varphi) n var_{\theta}\left(\frac{\partial}{\partial \theta} [\log f(X_1, \theta)]\right) = var_{\theta}(\varphi) n I(\theta)\end{aligned}$$

证毕。

- 由C-R不等式，参数无偏估计的方差有下界，一般情况下最好的阶为 $1/n$ （中心极限定理的阶为 $1/\sqrt{n}$ ）。
- 如果 $g(\theta)$ 的某无偏估计 φ 的方差达到了C-R不等式给出的下界，则 φ 就是 $g(\theta)$ 的最小方差无偏估计（第二种判定方法）。

第二节 估计的优良性标准

例1. 两点分布, $X \sim B(1, p)$,

$$f(x, p) = p^x (1-p)^{1-x}$$

$$\frac{\partial(\log f(x, p))}{\partial p} = \frac{x}{p} - \frac{1-x}{1-p}$$

$$\begin{aligned} I(p) &= E_p \left(\frac{X}{p} - \frac{1-X}{1-p} \right)^2 \\ &= \left(\frac{0}{p} - \frac{1}{1-p} \right)^2 (1-p) + \left(\frac{1}{p} - \frac{0}{1-p} \right)^2 p = \frac{1}{p(1-p)} \end{aligned}$$

● 当 $p = 1/2$ 时, Fisher信息量最小。

● \bar{X} 的方差为 $\text{var}_p(\bar{X}) = \frac{1}{n} p(1-p) = \frac{1}{nI(\theta)}$, 达到了C-R不等式的下界。

第二节 估计的优良性标准

例2. 正态分布, $X \sim N(\mu, \sigma_0^2)$, 其中 σ_0^2 已知。

则

$$f(x, \mu) = \frac{1}{\sqrt{2\pi}\sigma_0} e^{-\frac{1}{2\sigma_0^2}(x-\mu)^2}$$
$$\frac{\partial(\log f(x, \mu))}{\partial\mu} = \frac{x - \mu}{\sigma_0^2}$$
$$I(\mu) = \frac{E_\mu(X - \mu)^2}{\sigma_0^4} = \sigma_0^{-2}$$

● σ_0^2 越大, Fisher信息量越小。

● \bar{X} 的方差为 $\sigma_0^2/n = 1/nI(\mu)$, 达到了C-R不等式的下界, 是 μ 的最小方差无偏估计。

第二节 估计的优良性标准

例3. (P30例2.9) (其中计算提示: $\sum_{i=1}^n X_i$ 服从参数为 $n\lambda$ 的Poisson分布)

说明有时最小方差无偏估计也不可能达到C-R不等式的下界! (明显是人造的例子)

例4. 若 $X \sim U(0, \theta)$, 则 θ 的MLE为 $\max_{1 \leq i \leq n} X_i$, 矩估计为 $2\bar{X}$, 均有不足。

令 $\hat{\theta} = \frac{n+1}{n} \max_{1 \leq i \leq n} X_i$, 则 $\hat{\theta}$ 为 θ 的无偏估计 (实际上是最小方差无偏估计)。

容易验证, $Var_{\theta}(\hat{\theta}) = \frac{\theta^2}{n(n+2)}$, 以 $O(\frac{1}{n^2})$ 的速度趋向于0, 快于C-R不等式中的 $O(\frac{1}{n})$ 的阶。

原因: X 的支撑与参数 θ 有关。

第二节 估计的优良性标准

- 
- 请查找 $I(\theta)$ 的等价定义。
 - 若参数 θ 是 m 维的，也有相应的C-R不等式，可用于一般的正态分布。此时 $I(\theta)$ 变为 $m \times m$ 正定矩阵，称为Fisher信息矩阵， $g'(\theta)$ 变为列向量（梯度）， $\frac{(g'(\theta))^2}{nI(\theta)}$ 变为二次型 $\frac{1}{n} g'(\theta)^T I^{-1}(\theta) g'(\theta)$ 。请自行推导、补充。
 - 大样本性质：当样本量 n 趋向 ∞ 时的性质，如（强）相合性，还有收敛速度等。常有
$$\sqrt{n}(\hat{\theta}_n - \theta) \rightarrow N(0, \Sigma(\theta)).$$
 - 漸近协差阵 $\Sigma(\theta)$ 与 $I(\theta)$ 的关系？
 - 小样本性质：无偏性、最小方差、C-R不等式等，不要求 n 趋向 ∞ 。
 - 是否可以互推？相合估计 \Rightarrow 无偏？无偏估计 \Rightarrow 相合？证明或举反例。

第二节 估计的优良性标准

★ 统计方法的优良性标准？如高考录取：

状元；

前10（20）名录取数；

最低录取分数；

平均录取分数…。

是否应一致？

第三节 置信区间

- 
- 点估计：用 $\varphi(X_1, \dots, X_n)$ 估计 $g(\theta)$ 。一般一个完整的估计方法还要求给出或估计估计量的标准差（或方差），之后利用中心极限定理……
 - 区间估计：用随机区间 $[\varphi_1(X_1, \dots, X_n), \varphi_2(X_1, \dots, X_n)]$ 估计 $g(\theta)$ 。

定义1. 设 $\gamma \in (0, 1)$, $\varphi_1(X_1, \dots, X_n) \leq \varphi_2(X_1, \dots, X_n)$ 是两个统计量，称 $[\varphi_1(X_1, \dots, X_n), \varphi_2(X_1, \dots, X_n)]$ 是 $g(\theta)$ 的置信水平为 γ 的置信区间，若对任意的 $\theta \in \Theta$, 有

$$P_\theta\{\varphi_1(X_1, \dots, X_n) \leq g(\theta) \leq \varphi_2(X_1, \dots, X_n)\} \geq \gamma$$

- 一般地， φ_1 和 φ_2 皆为有限。
- 若刻意取 $\varphi_1 = -\infty$ 或 0 ，则称 φ_2 为置信上限。如污染浓度等。
- 若刻意取 $\varphi_2 = +\infty$ ，则称 φ_1 为置信下限。如寿命、航天等。

第三节 置信区间

- 
- 按照定义1， $(-\infty, +\infty)$ 永远是 $g(\theta)$ 的置信水平为 γ 的置信区间！
 - 优良性标准（非正式定义），一般地，用同一组数据，构造的置信区间越窄越好；置信上限越小越好；置信下限越大越好。
 - 一般地，置信水平越大，置信区间越宽。

正态分布参数置信区间的几种基本类型：

- 一、已知方差 $\sigma^2 = \sigma_0^2$ ，求期望 μ 的置信区间。
- 二、未知方差 σ^2 ，求期望 μ 的置信区间。
- 三、未知期望 μ ，求方差 σ^2 的置信区间。

第三节 置信区间

一、已知方差 $\sigma^2 = \sigma_0^2$, 求期望 μ 的置信区间

相对简单: 因为 $X_i \sim N(\mu, \sigma_0^2)$, 故而 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma_0^2}{n}\right)$, 所以

$$\eta = \frac{\bar{X} - \mu}{\sqrt{\sigma_0^2/n}} \sim N(0, 1)$$

若取 $\gamma = 0.95$, 则 $P(|\eta| \leq 1.96) = \gamma$, 因此, 解不等式 $|\eta| \leq 1.96$, 得 μ 的置信水平为95%的置信区间为

$$\left[\bar{X} - 1.96 \sqrt{\sigma_0^2/n}, \bar{X} + 1.96 \sqrt{\sigma_0^2/n} \right]$$

- 习惯上, γ 常取0.90, 0.95或0.99, 此时对应的常数为1.65, 1.96或2.58。
- 给定 $\gamma = 0.95$, 是否可以有别的水平恰为 γ 的置信区间?

第三节 置信区间

例1. 设滚珠直径 X 服从正态分布 $N(\mu, 0.05)$, 随机抽取6个, 测得其直径为: 14.70, 15.21, 14.90, 14.91, 15.32, 15.32, 试求 μ 的95%的置信区间。

解: $\bar{x} = \frac{1}{6} \sum_{i=1}^6 x_i = 15.06$, $1.96 \sqrt{0.05/6} \approx 0.18$, 故所求为
 $[15.06 - 0.18, 15.06 + 0.18] = [14.88, 15.24]$ 。

- 能否说, μ 以95%的概率落入[14.88, 15.24]?
- μ 是非随机的, [14.88, 15.24]是已知的, 无随机性, 无概率问题。
- 抽样前, $\left[\bar{X} - 1.96\sqrt{\sigma_0^2/n}, \bar{X} + 1.96\sqrt{\sigma_0^2/n}\right]$ 是随机区间, 以概率 $\gamma = 0.95$ 覆盖 μ !

第三节 置信区间

例1. 设滚珠直径 X 服从正态分布 $N(\mu, 0.05)$, 随机抽取6个, 测得其直径为: 14.70, 15.21, 14.90, 14.91, 15.32, 15.32, 试求 μ 的95%的置信区间。

解: $\bar{x} = \frac{1}{6} \sum_{i=1}^6 x_i = 15.06$, $1.96 \sqrt{0.05/6} \approx 0.18$, 故所求为
 $[15.06 - 0.18, 15.06 + 0.18] = [14.88, 15.24]$ 。

- 能否说, μ 以95%的概率落入[14.88, 15.24]?
- μ 是非随机的, [14.88, 15.24]是已知的, 无随机性, 无概率问题。
- 抽样前, $\left[\bar{X} - 1.96\sqrt{\sigma_0^2/n}, \bar{X} + 1.96\sqrt{\sigma_0^2/n}\right]$ 是随机区间, 以概率 $\gamma = 0.95$ 覆盖 μ !

第三节 置信区间

二、未知方差 σ^2 ，求期望 μ 的置信区间。

因为 σ^2 未知，“一”的方法无法使用，需要用其无偏估计 S^2 代替它。但如此一来，得到的 $T = \frac{\bar{X} - \mu}{\sqrt{S^2/n}}$ 不再服从正态分布，1.96也不能用了。

下面主要研究 T 的分布。

定理3.1. 设 X_1, \dots, X_n 独立同分布，共同分布为 $N(0, 1)$ ，则 $\xi = \sum_{i=1}^n X_i^2$ 服从 Γ 分布 $\Gamma(\frac{n}{2}, \frac{1}{2})$ 。

证明：（直接证明，如数学归纳法，略）

定义2：若 $\xi \sim \Gamma(\frac{n}{2}, \frac{1}{2})$ ，则称其服从 n 个自由度的 χ^2 分布，记为 $\xi \sim \chi^2(n)$ 。

其密度函数（不重要），草图（重要），为……。

第三节 置信区间



- 自由度是统计中非常重要的概念，来源于物理/力学，如火车有1个自由度，汽车有2个， R^n 中的任一点有 n 个自由度。 (R^1, R^2, R^3, \dots)
- 称 ξ 的自由度为 n ，是因为按照其统计背景，来源于 R^n 中随机向量 (X_1, \dots, X_n) 。但 ξ 自身是一维的。
- χ^2 分布是统计中3个重要分布之一，主要描述方差整体分布。

推论1. 若 $\xi \sim \chi^2(n)$ ，则 $E\xi = n$ 。

证明：略。

推论2. 若 $\xi \sim \chi^2(m)$, $\eta \sim \chi^2(n)$, ξ 与 η 相互独立，则 $\xi + \eta \sim \chi^2(m + n)$ 。

证明：取 X_1, \dots, X_{m+n} 独立同分布，共同分布为 $N(0, 1)$ ，令……

第三节 置信区间

定理3.2. 设 X_1, \dots, X_n 相互独立, $X_i \sim N(\mu_i, \sigma^2)$, $A = (a_{ij})$ 为n阶正交矩阵, 令 $(Y_1, \dots, Y_n)^T = A(X_1, \dots, X_n)^T$, 则 Y_1, \dots, Y_n 相互独立, 且
 $Y_i \sim N(\sum_{k=1}^n a_{ik}\mu_k, \sigma^2)$ 。

证明: (1) 首先考虑 $\mu_i = 0$ ($i = 1, \dots, n$)的情形。此时 $(X_1, \dots, X_n)^T$ 的联合密度为

$$\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2\right\}$$

对给定的实数 t_1, \dots, t_n , 令

$$D = \left\{ (x_1, \dots, x_n) : \sum_{j=1}^n a_{ij}x_j \leq t_i, i = 1, \dots, n \right\}$$

则 $P(Y_1 \leq t_1, \dots, Y_n \leq t_n) = \int_D \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2\right\} dx_1 \cdots dx_n$, 做变量替换 $(y_1, \dots, y_n)^T = A(x_1, \dots, x_n)^T$, 则 $(x_1, \dots, x_n)^T = A^T(y_1, \dots, y_n)^T$, 且 $\sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i^2$ 。

第三节 置信区间

因为 A 是正交矩阵，故其雅可比行列式绝对值为1。故

$$\begin{aligned} P(Y_1 \leq t_1, \dots, Y_n \leq t_n) &= \int_{-\infty}^{t_1} \cdots \int_{-\infty}^{t_n} \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n y_i^2 \right\} dy_1 \cdots dy_n \\ &= \prod_{i=1}^n \left[\int_{-\infty}^{t_i} \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{y_i^2}{2\sigma^2} \right\} dy_i \right] \end{aligned}$$

由此可知， Y_1, \dots, Y_n 相互独立，皆服从 $N(0, \sigma^2)$ 。

(2) 一般情形 (μ_i 不全为0)。令 $Z_i = X_i - \mu_i$ ，则 Z_1, \dots, Z_n 满足 (1) 的条件，故 $\sum_{j=1}^n a_{1j}Z_j, \dots, \sum_{j=1}^n a_{nj}Z_j$ 相互独立，共同分布为 $N(0, \sigma^2)$ 。而

$$Y_i = \sum_{j=1}^n a_{ij}Z_j + \sum_{j=1}^n a_{ij}\mu_j \quad (i = 1, \dots, n)$$

所以 Y_1, \dots, Y_n 相互独立，且 $Y_i \sim N(\sum_{k=1}^n a_{ik}\mu_k, \sigma^2)$ 。证毕。

第三节 置信区间

定理3.3. 设 X_1, \dots, X_n 相互独立, $X_i \sim N(\mu, \sigma^2)$, 则

$$(1) \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right);$$

$$(2) \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1);$$

(3) \bar{X} 与 $\sum_{i=1}^n (X_i - \bar{X})^2 = (X_1 - \bar{X})^2 + \dots + (X_n - \bar{X})^2$ 相互独立。

证明: 此时 $\mu_i \equiv \mu$ 。取 n 阶正交阵 A , 其第一行元素皆为 $1/\sqrt{n}$, 令 $Y_i = \sum_{j=1}^n a_{ij} X_j$, 由定理3.2, Y_1, \dots, Y_n 相互独立, $Y_i \sim N\left(\sum_{k=1}^n a_{ik} \mu, \sigma^2\right)$ 。故 $Y_1 \sim N(\sqrt{n}\mu, \sigma^2)$ 。

当 $i \geq 2$ 时, 因为 A 正交, 故 $\sum_{k=1}^n a_{ik} = 0$, 从而 $Y_i \sim N(0, \sigma^2)$ 。因此,

$$\bar{X} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i}{\sqrt{n}} = \frac{1}{\sqrt{n}} Y_1 \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

又因为 $\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n(\bar{X})^2 = \sum_{i=1}^n Y_i^2 - Y_1^2 = \sum_{i=2}^n Y_i^2$,

第三节 置信区间

所以

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=2}^n \left(\frac{Y_i}{\sigma} \right)^2 \sim \chi^2(n-1)$$

最后，由于 Y_1, \dots, Y_n 相互独立，故 $\bar{X} = \frac{1}{\sqrt{n}} Y_1$ 与 $\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=2}^n Y_i^2$ 相互独立。

- 此定理非常重要：如何利用正交变换将 S^2 中的 n 项相关的随机变量平方和变为相互独立的 $n - 1$ 项平方和。
- 关于自由度：虽然 $(X_1 - \bar{X}, \dots, X_n - \bar{X})^T \in R^n$ ，但因为 $\sum_{i=1}^n (X_i - \bar{X}) \equiv 0$ ，实际上分布它在 R^n 中的某 $n - 1$ 维子空间中，故仅有 $n - 1$ 个自由度。（或， \bar{X} 占了一个自由度）
- 此处自由度的统计学解释为：独立信息个数。

第三节 置信区间

现在研究 $T = \frac{\bar{X} - \mu}{\sqrt{s^2/n}}$, 显然

$$T = \frac{\sqrt{n}(\bar{X} - \mu)/\sigma}{\sqrt{\frac{1}{(n-1)\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2}}$$

可以看出, 分子为标准正态 $N(0, 1)$, 而分母中的 $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2$ 服从 $\chi^2(n-1)$, 故分子、分母的分布皆为完全已知 (与未知参数 μ 、 σ^2 无关) !

且相互独立, 故 T 的分布也是完全已知的, 不依赖于未知参数 μ 、 σ^2 。

定义3. 称随机变量 T 服从 n 个自由度的 t 分布, 记为 $T \sim t(n)$, 若 T 的分布密度为

$$p_n(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma(n)\sqrt{n\pi}} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}$$

第三节 置信区间

- 密度函数：不用背，但应知道其草图。
- 与标准正态密度区别：重尾（heavy-tailed）。

- 对 $\forall t \in R$ ，有 $\lim_{n \rightarrow \infty} p_n(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}t^2}$ 。

定理3.4. 设 ξ 与 η 相互独立， $\xi \sim N(0, 1)$, $\eta \sim \chi^2(n)$, 则

$$T = \frac{\xi}{\sqrt{\eta/n}} \sim t(n)$$

证明：略（随机变量函数的分布）。

- t 分布也称学生分布（Student distribution, Gosset 笔名 Student。）是统计中3个重要分布之一。

第三节 置信区间



回到我们的问题，则有重要结论：

$$T = \frac{\bar{X} - \mu}{\sqrt{s^2/n}} \sim t(n-1)$$

- 利用上述结论，很快得到 μ 的置信区间构造方法：给定置信水平 γ （如0.95），查 t 分布表（P354），自由度 $df = n - 1$ ，得临界值 λ ，满足

$$P(|T| \leq \lambda) = \gamma$$

解不等式得， μ 的置信水平为 γ 的置信区间为

$$\left[\bar{X} - \lambda \frac{s}{\sqrt{n}}, \bar{X} + \lambda \frac{s}{\sqrt{n}} \right]$$

- 由于 t 分布是已知分布，对给定的 n ，及常用置信水平0.90、0.95和0.99，前人早已完成制表工作。

第三节 置信区间

例2. 用仪器间接测量高温，重复5次，得到数据1250, 1265, 1245, 1260, 1275。设测量值服从正态分布 $N(\mu, \sigma^2)$ ，求 μ 的95%的置信区间。

解: $n = 5$, $\bar{X} = 1259$, $S^2 = \frac{1}{n-1} \sum_{i=1}^5 (X_i - \bar{X})^2 = \frac{570}{4}$ 。查t分布表 ($\gamma = 0.95$, $df=4$) , 得 $\lambda = 2.776$, 故置信区间为: $[\bar{X} - \lambda \frac{S}{\sqrt{n}}, \bar{X} + \lambda \frac{S}{\sqrt{n}}] = [1244.2, 1273.8]$ 。

三、未知期望 μ , 求 σ^2 的置信区间。

由定理3.3的 (2) , $Y = \frac{(n-1)S^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1)$, 对于给定的 γ , 查 χ^2 分布表得 $\lambda_1 < \lambda_2$ (画图) , 使得 $P(Y < \lambda_1) = P(Y > \lambda_2) = \frac{1-\gamma}{2}$, 则 $P(\lambda_1 \leq Y \leq \lambda_2) = \gamma$, 即

第三节 置信区间

$$P\left(\frac{(n-1)S^2}{\lambda_2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\lambda_1}\right) = \gamma$$

即

$$\left[\frac{1}{\lambda_2} \sum_{i=1}^n (X_i - \bar{X})^2, \frac{1}{\lambda_1} \sum_{i=1}^n (X_i - \bar{X})^2\right]$$

是 σ^2 的置信水平为 γ 的置信区间。

例2（续）查 χ^2 分布表 ($\gamma = 0.95$, $df=4$) 得 $\lambda_1 = 0.484$, $\lambda_2 = 11.1$, 故 σ^2 的95%的置信区间[51.35, 1177.69]。

如果取 $\widetilde{\lambda_1} = 0$ （类似于 $-\infty$ ），则 $\widetilde{\lambda_2} = 9.49$ ，故 σ^2 的95%的置信下限为60.06；同理， σ^2 的95%的置信上限为 $\frac{1}{\widetilde{\lambda_1}} \sum_{i=1}^n (X_i - \bar{X})^2$ ，本书 $\widetilde{\lambda_1}$ 查不到。

- 该置信区间的优良性：未提及。

第三节 置信区间

● 枢轴量方法：找枢轴量（非统计量）满足

- ① 其表达式中包含且仅包含我们感兴趣的参数；
- ② 其分布已知，与参数无关。

对情况一，枢轴量为 $\eta = \frac{\bar{X} - \mu}{\sqrt{\sigma_0^2/n}}$ ；

对情况二，枢轴量为 $T = \frac{\bar{X} - \mu}{\sqrt{S^2/n}}$ ；

对情况三，枢轴量为 $Y = \frac{(n-1)S^2}{\sigma^2}$ 。

通过解不等式，可以得到感兴趣参数的置信区间。

思考：若 $\mu = \mu_0$ 已知，如何求 σ^2 的置信区间？

● 枢轴量方法不足：① 如何找？缺乏统一方法；② 优良性？

第三节 置信区间

● 统计量方法* (多用于可靠性中寻找置信下限等)

设 $X_i \sim F(x, \theta)$, $g(\theta)$ 为 Θ 上的实值函数 (目标), 又设 $\varphi(X_1, \dots, X_n)$ 为任一实值统计量, 令

$$G(u, \theta) = P_\theta(\varphi(X_1, \dots, X_n) \geq u) = 1 - P_\theta(\varphi(X_1, \dots, X_n) < u)$$

则易证, $G(u, \theta)$ 是 u 的左连续减函数 ($1 - G(u + 0, \theta)$ 是分布函数)。给定置信水平 $0 < \gamma < 1$, 对固定样本 x_1, \dots, x_n , 记 $u = \varphi(x_1, \dots, x_n)$, 令

$$g_L(u) = \inf\{g(\theta): \theta \in \Theta, G(u, \theta) \geq 1 - \gamma\}$$

$$g_U(u) = \sup\{g(\theta): \theta \in \Theta, G(u + 0, \theta) \leq \gamma\}$$

如同通常情况, 当 $\{\theta \in \Theta, G(u, \theta) \geq 1 - \gamma\}$ 为空集时, 定义

$g_L(u) = \sup\{g(\theta): \theta \in \Theta\}$; 当 $\{\theta \in \Theta, G(u + 0, \theta) \leq \gamma\}$ 为空集时, 定义
 $g_U(u) = \inf\{g(\theta): \theta \in \Theta\}$ 。

第三节 置信区间

定理3.5. $g_L(\varphi(X_1, \dots, X_n))$ 是 $g(\theta)$ 的水平为 γ 的置信下限, 即

$$P_\theta(g(\theta) \geq g_L(\varphi(X_1, \dots, X_n))) \geq \gamma \quad \forall \theta \in \Theta$$

证明: 固定 $\theta \in \Theta$, 令 $c = \sup\{u: G(u, \theta) \geq 1 - \gamma\}$, 则 (画图)

$$G(c, \theta) \geq 1 - \gamma \geq G(c + 0, \theta) \tag{1}$$

由 g_L 的定义可知,

$$g(\theta) < g_L(u) \Rightarrow G(u, \theta) < 1 - \gamma \quad (g_L(u) \text{ 是下确界}) \tag{2}$$

再由 (1) 式及 G 对 u 单调减知,

$$G(u, \theta) < 1 - \gamma \Rightarrow u > c \tag{3}$$

因此,

$$\begin{aligned} & P_\theta(g(\theta) < g_L(\varphi(X_1, \dots, X_n))) \\ & \leq (\text{由2}) P_\theta(G(\varphi(X_1, \dots, X_n), \theta) < 1 - \gamma) \\ & \leq (\text{由3}) P_\theta(\varphi(X_1, \dots, X_n) > c) \\ & \leq G(c + 0, \theta) \leq (\text{由1}) 1 - \gamma \end{aligned}$$

证毕。

证明不长, 但看起来较难。一是不熟悉, 二是“下确界”等。

第三节 置信区间

● 同理可知， $g_U(\varphi(X_1, \dots, X_n))$ 是 $g(\theta)$ 的水平为 γ 的置信上限，即

$$P_\theta(g(\theta) \leq g_U(\varphi(X_1, \dots, X_n))) \geq \gamma \quad \forall \theta \in \Theta$$

● $[g_L(\varphi(X_1, \dots, X_n)), g_U(\varphi(X_1, \dots, X_n))]$ 是 $g(\theta)$ 的水平为 $2\gamma - 1$ 的置信区间。

例3. 设 $X \sim N(\mu, \sigma^2)$ ，数据为 X_1, \dots, X_n ，求 σ^2 的置信上限（例2（续）后已提及）。

解：取 $\varphi(X_1, \dots, X_n) = \sum_{i=1}^n (X_i - \bar{X})^2$ ，则

$$\begin{aligned} G(u, \sigma^2) &= P\left(\sum_{i=1}^n (X_i - \bar{X})^2 \geq u\right) \\ &= P\left(\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \geq \frac{u}{\sigma^2}\right) = 1 - H\left(\frac{u}{\sigma^2}\right) \end{aligned}$$

其中 $H(\cdot)$ 为 $\chi^2(n-1)$ 的分布函数。

第三节 置信区间

易知 G 是 σ^2 的连续增函数，设 $g_U(u)$ 满足方程 $G(u, g_U(u)) = \gamma$ ，即

$$1 - H\left(\frac{u}{g_U(u)}\right) = \gamma$$

$H\left(\frac{u}{g_U(u)}\right) = 1 - \gamma$ ，查表（0.95查不到！）得临界值 λ ，则 $g_U(u) = \frac{u}{\lambda}$ ，即

$g_U(X_1, \dots, X_n) = \frac{1}{\lambda} \sum_{i=1}^n (X_i - \bar{X})^2$ 为 σ^2 的置信上限（与枢轴量方法相同）。

例4. 某型号火箭发射3次，皆成功，求成功率 p 的95%的置信下限。

-----end 20240304

解：取统计量 $\varphi(X_1, \dots, X_3) = \sum_{i=1}^3 X_i$ ，则 $G(u, p) = P_p(\sum_{i=1}^3 X_i \geq u)$ ，故

$$G(3, p) = P_p\left(\sum_{i=1}^3 X_i \geq 3\right) = p^3,$$

$$G(2, p) = P_p\left(\sum_{i=1}^3 X_i \geq 2\right) = 3p^2 - 2p^3, \dots \dots$$

第三节 置信区间

易知 G 是 σ^2 的连续增函数，设 $g_U(u)$ 满足方程 $G(u, g_U(u)) = \gamma$ ，即

$$1 - H\left(\frac{u}{g_U(u)}\right) = \gamma$$

$H\left(\frac{u}{g_U(u)}\right) = 1 - \gamma$ ，查表（0.95查不到！）得临界值 λ ，则 $g_U(u) = \frac{u}{\lambda}$ ，即

$g_U(X_1, \dots, X_n) = \frac{1}{\lambda} \sum_{i=1}^n (X_i - \bar{X})^2$ 为 σ^2 的置信上限（与枢轴量方法相同）。

例4. 某型号火箭发射3次，皆成功，求成功率 p 的95%的置信下限。

解：取统计量 $\varphi(X_1, \dots, X_3) = \sum_{i=1}^3 X_i$ ，则 $G(u, p) = P_p(\sum_{i=1}^3 X_i \geq u)$ ，故

$$G(3, p) = P_p\left(\sum_{i=1}^3 X_i \geq 3\right) = p^3,$$

$$G(2, p) = P_p\left(\sum_{i=1}^3 X_i \geq 2\right) = 3p^2 - 2p^3, \dots \dots$$

第三节 置信区间

现在数据为 $\sum_{i=1}^3 X_i = 3$, 故由方程 $G(3, p_L) = 1 - \gamma = p_L^3$, 得到

$$p_L = \sqrt[3]{1 - \gamma} = \sqrt[3]{0.05} \approx 0.368$$

可以证明, 这是最好的置信下限!

- 统计量方法如何选统计量? 可选充分统计量、或MLE。
- 参数空间多维时, 可以有置信域 (Confidence region) 。
- 近现代统计中, 难以构造精确置信区间, 常用

$$[\hat{\theta} - 1.96\hat{s}, \hat{\theta} + 1.96\hat{s}]$$

其覆盖率为95%。

第四节 分布函数与密度函数的估计

- 参数的 (Parametric) : 参数空间有限维;
- 非参数的 (Non-parametric): 参数空间无穷维, 如估计函数;
- 半参数的 (Semi-parametric) : 有限维部分+ (或乘) 无穷维部分。

一、分布函数 $F(x)$ 的估计 (不假定 X 的分布类型, 非参数问题)

设样本为简单随机样本 X_1, \dots, X_n , 对于任意固定的 x , 因为 $F(x) = P(X \leq x)$, 用频率估计概率, 得 $F(x)$ 的无偏估计量 $\frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(X_i) = \frac{1}{n} \sum_{i=1}^n I_{[X_i, \infty)}(x)$ 。由强大数律, $P\left(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(X_i) = F(x)\right) = 1$ 。

定义1. 称 $F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(X_i) = \frac{1}{n} \sum_{i=1}^n I_{[X_i, \infty)}(x)$ 为 X 的经验分布函数。

- $F_n(x)$ 为右连左极阶梯函数, 是以 $\frac{1}{n}$ (若 X_i 不相等) 概率取 X_i 的随机变量的分布函数。

第四节 分布函数与密度函数的估计

定理4.1. (Glivenko-Cantelli)

$$P\left(\lim_{n \rightarrow \infty} \sup_{x \in (-\infty, \infty)} |F_n(x) - F(x)| = 0\right) = 1$$

证明：略。

定理说明， $F_n(x)$ 一致收敛于 $F(x)$ 。

二、密度函数 $f(x)$ 的估计

(一)、直方图法

对任意 $x \in (c, d]$ ，若 $f(x)$ 较大，则样本 X_1, \dots, X_n 落入 $(c, d]$ 的会较多。估计的思想将其反过来。由于

$$P(c < X \leq d) = \int_c^d f(t) dt \approx f(x)(d - c)$$

第四节 分布函数与密度函数的估计

再用频率估计概率 $P(c < X \leq d)$, 得到 $f(x)$ 的估计量

$$\widehat{f(x)} = \frac{1}{n(d-c)} \sum_{i=1}^n I_{(c, d]}(X_i)$$

直方图法就是利用上述想法, 但 c 、 d 的取法等有规范。

- 将样本值重新排序, 得顺序统计量 $X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$ 。
- 取常数 a 略小于 $X_{(1)}$, b 略大于 $X_{(n)}$, 将 $[a, b]$ 等分为 m 个区间 $(t_i, t_{i+1}]$, 其中 $i = 0, \dots, m - 1$, $t_i = a + i \cdot \frac{b-a}{m}$, $t_0 = a$, $t_m = b$ (m 的选取依赖 n , 区间 “左开右闭” 是为了规范)。
- 记 v_i 为 X_1, \dots, X_n 中落入 $(t_i, t_{i+1}]$ 的频数, $h = \frac{b-a}{m}$ 。
- 在数轴上做以 $[t_i, t_{i+1}]$ 为底, 以 $\frac{v_i}{nh}$ 为高的 m 个矩形, 得直方图。

第四节 分布函数与密度函数的估计

- m 的选取依赖 n , n 越大, m 相应也越大。
- 得到的估计是阶梯函数, 一定条件下, 是相合的。
- 优点: 简单、方便、易于理解。

例1. 教材P52, 例4.2…… (有了直方图后, 多年前的统计软件就可以在你输入不同分布类型后, 画出最好的拟合曲线, 直观上帮助你建模)

(二) 、核估计法

希望对直方图方法进行改进, 更精细一些, 且估计量可以有较好的数学性质, 如连续。

定义2. 设 $K(x) \geq 0$, $\int_{-\infty}^{\infty} K(x)dx = 1$, 称其为核函数, 称

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

为 $f(x)$ 的核估计, 称 $h > 0$ 为其窗宽。 (加权平均, 权重可随 x 随时变化)

第四节 分布函数与密度函数的估计

- 核估计为一类估计，其中的核函数 $K(x)$ 、窗宽 h 由操作者选取，选的好，估计效果也好。
- 一般地， $K(x)$ 常常选为关于原点对称的（单峰）函数，如：

$$K_0(x) = \begin{cases} \frac{1}{2} & \text{当 } -1 \leq x \leq 1 \\ 0 & \text{否则} \end{cases}$$

$$K_1(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}$$

$$K_2(x) = \frac{1}{\pi(1+x^2)}$$

等。

第四节 分布函数与密度函数的估计

- 一般当数据离 x 越近时， $K\left(\frac{x-X_i}{h}\right)$ 越大，说明数据 X_i 对估计的贡献大。
- 窗宽 h 越小，说明越重视靠近 x 的数据，而轻视远离 x 的数据。一般地，若数据量大，窗宽可取的较小；数据量小，窗宽不得不取的较大。
- 样本固定时，窗宽 h 大，核估计平滑；窗宽 h 小，核估计波动大。
- 当取 $K(x) = K_0(x)$ 时，

$$f_n(x) = \frac{1}{2hn} \sum_{i=1}^n I_{(x-h, x+h]}(X_i) = \frac{1}{2h} [F_n(x+h) - F_n(x-h)]$$

其中 $F_n(\cdot)$ 为经验分布函数。由微积分基本定理，一定条件下，约等于 $f(x)$ 。此时的 $f_n(x)$ 称为Rosenblatt估计（最早的核估计）。

第四节 分布函数与密度函数的估计

- 一定条件下有强相合性。
- 当 $K(x)$ 与 h 选的好时，核估计比直方图估计好。
- 有寻找最优窗宽的相关成熟方法。
- 容易验证， $\int_{-\infty}^{\infty} f_n(x) dx \equiv 1$ 。
- $f_n(x)$ 是非参数的，其收敛速度达不到一般参数估计的 $O(n^{-\frac{1}{2}})$ 收敛速度。