

## 第二节 序贯概率比检验法

定义1. 称序贯检验法 $\Delta = (\tau^*, d^*)$ 为序贯概率比检验 (SPRT) , 如果

$$\tau^* = \inf\{n: n \geq 1, \lambda_n \notin (A, B)\}$$

$$d^* = \begin{cases} 1 & \text{若 } \lambda_{\tau^*} \geq B \\ 0 & \text{若 } \lambda_{\tau^*} \leq A \end{cases}$$

简记为 $S(A, B)$ 。

由 $\lambda_n$ 的定义,  $\log(\lambda_n) = \sum_{i=1}^n \log\left(\frac{f_2(X_i)}{f_1(X_i)}\right)$ 是一个随机游动, 因此

$$\tau^* = \inf\{n: n \geq 1, \log(\lambda_n) \notin (\log A, \log B)\}$$

是停时, 即 $\Delta = (\tau^*, d^*)$ 确为序贯检验法。

定理1. 如果 $\mu\{x: f_1(x) \neq f_2(x)\} > 0$ , 则

$$P_i(\tau^* < \infty) = 1 \quad (i = 1, 2)$$

证明: 略。

## 第二节 序贯概率比检验法

例1. 两点分布的检验， $X \sim B(1, p)$ ,

$$H_1: p = p_1 \leftrightarrow H_2: p = p_2$$

其中 $0 < p_1 < p_2 < 1$ 是已知的常数，求SPRT。

解： $f_1(x) = p_1^x(1 - p_1)^{1-x}$ ,  $f_2(x) = p_2^x(1 - p_2)^{1-x}$ , 所以

$$\lambda_n = \prod_{i=1}^n \left(\frac{p_2}{p_1}\right)^{x_i} \left(\frac{1-p_2}{1-p_1}\right)^{1-x_i} = \left(\frac{p_2}{p_1}\right)^{S_n} \left(\frac{1-p_2}{1-p_1}\right)^{n-S_n}$$

其中 $S_n = \sum_{i=1}^n x_i$ 。故而，

$$\log \lambda_n = S_n \log \frac{p_2}{p_1} + (n - S_n) \log \left(\frac{1-p_2}{1-p_1}\right)$$

由 $\log \frac{p_2}{p_1} > 0$ ,  $\log \left(\frac{1-p_2}{1-p_1}\right) < 0$ , 易知

$$\begin{aligned}\lambda_n \geq B &\Leftrightarrow S_n \geq R_n = :cn + d_1 \\ \lambda_n \leq A &\Leftrightarrow S_n \leq A_n = :cn + d_2\end{aligned}$$

## 第二节 序贯概率比检验法

其中

$$c = -\frac{\log(1-p_2) - \log(1-p_1)}{\log p_2 - \log p_1 - \log(1-p_2) + \log(1-p_1)} \in (0, 1)$$

$$d_1 = \frac{\log B}{\log p_2 - \log p_1 - \log(1-p_2) + \log(1-p_1)} > 0$$

$$d_2 = \frac{\log A}{\log p_2 - \log p_1 - \log(1-p_2) + \log(1-p_1)} < 0$$

因此， $\tau^* = \inf\{n: n \geq 1, S_n \notin (A_n, R_n)\}$ 。

图像显示（画图），中间是继续区域，左上方拒绝，右下方接受。

● 形式简单，实用。

## 第二节 序贯概率比检验法

例2. 正态分布情形。设 $X \sim N(\theta, 1)$ ,

$$H_1: \theta = \theta_1 \leftrightarrow H_2: \theta = \theta_2$$

其中 $\theta_1 < \theta_2$ 是已知常数，求SPRT。

解：

$$\lambda_n = \prod_{i=1}^n \frac{f(x_i, \theta_2)}{f(x_i, \theta_1)} = \dots = e^{(\theta_2 - \theta_1)S_n - \frac{n}{2}(\theta_2^2 - \theta_1^2)}$$

其中 $S_n = \sum_{i=1}^n x_i$ 。因此，

$$\log \lambda_n = (\theta_2 - \theta_1)S_n - \frac{n}{2}(\theta_2^2 - \theta_1^2)$$

令

$$A_n = \frac{\theta_1 + \theta_2}{2} \cdot n + \frac{\log A}{\theta_2 - \theta_1}$$

$$R_n = \frac{\theta_1 + \theta_2}{2} \cdot n + \frac{\log B}{\theta_2 - \theta_1}$$

## 第二节 序贯概率比检验法

则

$$\tau^* = \inf\{n: n \geq 1, S_n \notin (A_n, R_n)\}$$

图像为（画图）……，与两点分布情形类似，但 $S_n$ 不必取整数值。

一个序贯检验法将平面分成3个区域：接受、拒绝、继续区域，SPRT由两条平行线划分，其斜率与 $H_1$ 、 $H_2$ 有关，而其截距与 $A$ 、 $B$ 有关。

如何选取 $A$ 、 $B$ ？取决于第I、第II类错误。

记 $\alpha = P_1(\tau^* < \infty, \lambda_{\tau^*} \geq B)$ （当 $H_1$ 成立时，停止并拒绝 $H_1$ ，即以真为假）， $\beta = P_2(\tau^* < \infty, \lambda_{\tau^*} \leq A)$ （当 $H_2$ 成立时，停止并接受 $H_1$ ，即以假为真）。我们不加证明地给出下列结论。

定理2.  $\alpha \leq \frac{1}{B}(1 - \beta)$ ,  $\beta \leq A(1 - \alpha)$ 。

## 第二节 序贯概率比检验法

这是两个很好的不等式：无论 $f_1$ 、 $f_2$ 是什么分布，均可用 $A$ 、 $B$ 直接来控制 $\alpha$ 、 $\beta$ （其它部分约为1）。

实际应用中，可采用近似方案：给定 $\alpha$ 、 $\beta$ ，取 $A^* = \frac{\beta}{1-\alpha}$ ， $B^* = \frac{1-\beta}{\alpha}$ ，则一般地， $A^*$ 、 $B^*$ 与目标 $A$ 、 $B$ 相差不大。对于序贯概率比检验法 $S(A^*, B^*)$ ，记 $\alpha^*$ 、 $\beta^*$ 分别为其第I、第II类错误的概率，则有：

定理3.  $\alpha^* \leq \frac{\alpha}{1-\beta}$ ， $\beta^* \leq \frac{\beta}{1-\alpha}$ ， $\alpha^* + \beta^* \leq \alpha + \beta$ 。

证明：略（不难）。

● 采用近似方案，第I、第II类错误的概率与原定的 $\alpha$ 、 $\beta$ 差距不大，且并不增大两类错误概率之和，早期很有意义。

## 第二节 序贯概率比检验法

定理4. 设 $\tilde{\Delta} = (\tilde{\tau}, \tilde{d})$ 为任一序贯检验法，其两类错误的概率满足 $\tilde{\alpha} \leq \alpha$ ,  $\tilde{\beta} \leq \beta$ ，其中 $\alpha$ 、 $\beta$ 为 $S(A, B)$ 的两类错误的概率，则有

$$E_i \tau^* \leq E_i \tilde{\tau} \quad i = 1, 2$$

● 说明其最优化：在控制两类错误概率的条件下，SPRT的平均样本量最小。

● 教材P286表2.1、表2.2表明，与固定样本量方法比较，许多情况下，大约可以节省50%的样本（ $\mu_i$ 为 $H_i$ 成立时平均样本量/固定样本量）。

例3. 秘书问题：10人依次面试应聘，面试前 $i$ 个人后，可知其排序，面试后需立即表示是否录用（仅1人），求使得找到最优者概率最大的策略。

例4. 设 $X_1, \dots, X_n, \dots$ 独立同分布， $c > 0$ 为每次观测费用，求 $\tau$ 使得  
 $E(\max\{X_1, \dots, X_\tau\} - c\tau)$   
最大。

# 第七章 统计决策与贝叶斯统计大意

统计决策与贝叶斯统计关系密切，考虑问题的角度、方法有一些类似之处。如都利用数据之外的信息。

可以独立发展，课程中也可独立讲授，但往往放在一起。

有贝叶斯决策理论。

## 第一节 统计决策问题概述

决策论研究当存在未知因素及随机性（不确定性）时，如何利用统计知识做出决策。

仍假设未知参数为  $\theta \in \Theta$ ，数据仍为  $X = (X_1, \dots, X_n) \in \mathfrak{X}$ 。

任一可能的决策称为行动  $a \in A$ ， $A$  称为行动空间。

# 第一节 统计决策问题概述

统计决策（函数）：样本空间 $\mathfrak{X}$ 到行动空间 $A$ 的一个可测映射： $\delta = \delta(X_1, \dots, X_n) \in A$ ，即当观测到数据 $X_1, \dots, X_n$ 时，采取行动 $\delta \in A$ 。

例1. 在参数估计问题中，若用 $\varphi(X_1, \dots, X_n)$ 估计目标 $\theta$ ，则 $A = \Theta$ ， $\delta(X_1, \dots, X_n) = \varphi(X_1, \dots, X_n)$ ，所以估计问题包含于决策理论中。

例2. 在假设检验问题中， $A = \{a_0, a_1\} = \{0, 1\}$ ，其中 $a_0 = 0$ 表示接受 $H_0$ ， $a_1 = 1$ 表示否定 $H_0$ ，所以检验问题包含于决策理论中（随机化检验情形， $A = [0, 1]$ ）。

● 新理论应包含新内容。

损失函数 $L(\theta, a)$ ：表示当参数真值为 $\theta$ 时，采取行动 $a$ 造成的损失。一般要求 $L(\theta, a) \geq -K > -\infty$ ，故不失一般性，常假设 $L(\theta, a) \geq 0$ 。

# 第一节 统计决策问题概述

● 估计问题中，常用的损失函数有：

① 平方损失函数： $L_1(\theta, a) = (a - \theta)^2$ ；

② 绝对偏差损失函数： $L_2(\theta, a) = |a - \theta|$ 。

均表示估计越准确，损失越小。

● 检验问题中，常用的损失函数为：

$$L(\theta, a_0) = \begin{cases} 0 & \text{当 } \theta \in \Theta_0 \\ l_2 & \text{当 } \theta \notin \Theta_0 \end{cases}, \quad L(\theta, a_1) = \begin{cases} l_1 & \text{当 } \theta \in \Theta_0 \\ 0 & \text{当 } \theta \notin \Theta_0 \end{cases}$$

其中  $l_1 > 0$ ,  $l_2 > 0$  为已知常数。即犯第一类错误的损失为  $l_1$ , 犯第二类错误的损失为  $l_2$ , 不犯错误的损失为 0。

当  $l_1 = l_2 = 1$  时，称为 0-1 损失。当  $l_1 \neq l_2$  时，表示两类错误后果不同。

定义 1. 称  $R(\theta, \delta) = E_\theta L(\theta, \delta(X_1, \dots, X_n))$  为决策  $\delta$  的风险函数（表示参数为  $\theta$  时，决策  $\delta$  的平均损失）。

# 第一节 统计决策问题概述

- 统计决策的最优解（最优决策）：如果决策 $\delta^*$ 使得对任意决策 $\delta$ ，有

$$R(\theta, \delta^*) \leq R(\theta, \delta) \quad \forall \theta \in \Theta$$

- 最优解要求太高，常常不存在。例如，估计问题中，若取

$L_1(\theta, a) = (a - \theta)^2$ ，则最优解就是最小均方误差估计（一般不存在）。

定义2. 称决策 $\delta$ 是（可）容许的，若不存在另一决策 $\delta'$ ，使得 $R(\theta, \delta') \leq R(\theta, \delta)$  ( $\forall \theta \in \Theta$ )，且对某 $\theta_0 \in \Theta$ ，不等式严格成立。

定义3. 称决策 $\delta^*$ 是minimax决策，若对一切决策 $\delta$ ，有

$$\sup\{R(\theta, \delta^*), \theta \in \Theta\} \leq \sup\{R(\theta, \delta), \theta \in \Theta\}$$

- minimax准则：先对所有 $\theta$ 求风险函数的最大值，再对 $\delta$ 求最小。

- 因为minimax准则比较的是最糟糕的情形，必然是保守的（例如保研时，maxmini，看谁最低分的课程分数高，不是好标准）。

# 第一节 统计决策问题概述

参数空间 $\Theta$ 、样本空间 $X$ 、行动空间 $A$ 和损失函数 $L$ 合称统计决策问题的四个要素。

例3. (教材P298, 例1.1) 检查设备零件, 其可能状态为:  $\theta_1$  (好) 、 $\theta_2$  (坏), 可能采取的行动为:  $a_1$  (保留) 、 $a_2$  (更换) 或 $a_3$  (修理) , 损失函数为:

|            | $a_1$ | $a_2$ | $a_3$ |
|------------|-------|-------|-------|
| $\theta_1$ | 0     | 10    | 5     |
| $\theta_2$ | 12    | 1     | 6     |

样本为 $X = 0, 1$ , 分别表示零件温度发烫、正常, 其分布为:

|            | $x = 0$ | $x = 1$ |
|------------|---------|---------|
| $\theta_1$ | 0.3     | 0.7     |
| $\theta_2$ | 0.6     | 0.4     |

问, 采取何种决策使得损失尽量地小?

# 第一节 统计决策问题概述

此问题既非估计，又非检验，显示统计决策包含更一般的问题。

解法为穷举法（全离散，共 $3^2 = 9$ 个可能决策）：

|         | $\delta_1$ | $\delta_2$ | $\delta_3$ | $\delta_4$ | $\delta_5$ | $\delta_6$ | $\delta_7$ | $\delta_8$ | $\delta_9$ |
|---------|------------|------------|------------|------------|------------|------------|------------|------------|------------|
| $x = 0$ | $a_1$      | $a_1$      | $a_1$      | $a_2$      | $a_2$      | $a_2$      | $a_3$      | $a_3$      | $a_3$      |
| $x = 1$ | $a_1$      | $a_2$      | $a_3$      | $a_1$      | $a_2$      | $a_3$      | $a_1$      | $a_2$      | $a_3$      |

由分布及损失函数，可以计算出风险函数

$$R(\theta, \delta) = E[L(\theta, \delta(X))] = \dots$$

例如 $R(\theta_1, \delta_2) = L(\theta_1, a_1)P(\delta_2(X) = a_1) + L(\theta_1, a_2)P(\delta_2(X) = a_2) + L(\theta_1, a_3)P(\delta_2(X) = a_3) = 0 \times 0.3 + 10 \times 0.7 + 5 \times 0 = 7$ 。所有结果列表如下：

# 第一节 统计决策问题概述

|                       | $\delta_1$ | $\delta_2$ | $\delta_3$ | $\delta_4$ | $\delta_5$ | $\delta_6$ | $\delta_7$ | $\delta_8$ | $\delta_9$ |
|-----------------------|------------|------------|------------|------------|------------|------------|------------|------------|------------|
| $R(\theta_1, \delta)$ | 0          | 7          | 3.5        | 3          | 10         | 6.5        | 1.5        | 8.5        | 5          |
| $R(\theta_2, \delta)$ | 12         | 7.6        | 9.6        | 5.4        | 1          | 3          | 8.4        | 4          | 6          |

按照定义2， $\delta_1$ 、 $\delta_4$ 、 $\delta_5$ 、 $\delta_6$ 、 $\delta_7$ 是容许的， $\delta_2$ 、 $\delta_3$ 、 $\delta_8$ 、 $\delta_9$ 是不容许的（如 $\delta_2$ 一致地不如 $\delta_4$ ）。

minimax决策为 $\delta_4$ ，其含义为：正常时保留，发烫时更换。

例4. 设 $X \sim N(\theta, 1)$ ，样本为一个观测值， $L(\theta, a) = (a - \theta)^2$ ，目的为估计参数 $\theta$ 。考察所有形如 $\delta_c(X) = cX$ 的决策，则

# 第一节 统计决策问题概述

$$\begin{aligned} R(\theta, \delta_c) &= E_{\theta} L(\theta, \delta_c(X)) = E_{\theta} (\theta - cX)^2 \\ &= E_{\theta} [c(\theta - X) + (1 - c)\theta]^2 \\ &= c^2 E_{\theta} (\theta - X)^2 + 2c(1 - c)E_{\theta} (\theta - X) + (1 - c)^2 \theta^2 \\ &= c^2 + (1 - c)^2 \theta^2 \end{aligned}$$

当  $c > 1$  时,  $R(\theta, \delta_c) = c^2 + (1 - c)^2 \theta^2 > 1 = R(\theta, \delta_1)$ , 因此  $\delta_c$  不是可容许的;

当  $c < 0$  时,  $R(\theta, \delta_c) = c^2 + (1 - c)^2 \theta^2 > c^2 + (1 + c)^2 \theta^2 = R(\theta, \delta_{-c})$ , 因此  $\delta_c$  也不是可容许的;

当  $0 \leq c \leq 1$  时, 不同的  $\delta_c$  之间无法比较。可以证明, 它们都是可容许的。

$R(\theta, \delta_1)$  与  $R(\theta, \delta_{0.5})$  的图像为 (……)

# 第一节 统计决策问题概述

因为

$$\sup\{R(\theta, \delta_c), \theta \in \Theta\} = \begin{cases} 1 & \text{当 } c = 1 \\ +\infty & \text{否则} \end{cases}$$

故而（非严格证明），minimax决策为  $\delta_1 = X$ 。

● 从例4可以看出，可容许性是很弱的要求，仅排除一些最不合理的  $\delta_c$ 。而  $\delta_1$ 、 $\delta_{0.5}$ 、甚至  $\delta_0$ （即不管数据是什么，总用0估计  $\theta$ ）都是可容许的。

● 效用函数 (Utility function)：其一般图像为……

● 在商业保险中的解释与作用……：  $X$ ：不买保险时的收益（负值为损失），  $Y$ ：买保险时的收益，

$$EX > EY$$

但

$$EU(X) < EU(Y)$$

## 第二节 什么是贝叶斯统计（简介）

- 以往比较不同统计方法时，常需比较参数 $\theta$ 的两个函数，难有“一致”性。是否可以比较两个函数的“平均”？
- 技术层面上，需要计算“加权（对参数 $\theta$ ）”平均，从而需要“权重”，即需要参数 $\theta$ 有“密度”。

Bayes学派（Bayesian）将未知参数 $\theta$ 看成随机变量（随机向量、随机元），从而有密度。

- 思想基础是Bayes公式（逆概率公式）。
- 称对立者为频率学派（Frequentist）。
- 发展较快，尤其近年来，因MCMC的发展。
- 见吴喜之，现代贝叶斯统计学（2000）。

## 第二节 什么是贝叶斯统计



### ● 一个例子（改自 Savage (1961)）

- ① 某人说，他仅听几个小节，就能分出是海顿或莫扎特的作品，随机地播放了10段音乐（5:5），他全分对了；
- ② 某人说，她能够尝出咖啡中，是将牛奶倒入咖啡，还是将咖啡倒入牛奶，随机地倒了10杯（5:5），她全尝对了；
- ③ 某人说（喝醉后），他能预测你投掷硬币的正反面，随机地测10次（5:5），他全预测对了。

能否认为他（她）真具备这些能力？

严格按照传统统计学家观点，这是检验问题  $H_0: p = \frac{1}{2}$ ，无论使用何种检验法，因为数据相同，结论也应相同。

常识告诉我们：①是真的；③是假的；②待定！我们使用了数据外的知识。

## 第二节 什么是贝叶斯统计

又如，中国队组队后，对某队的以往比赛成绩是3战皆胜。如何预测下一场的胜负？按频率学派， $\hat{p} = \bar{x} = 1$ ，故预测下一场必胜。贝叶斯学派给出的点估计可以是 $4/5 = 0.8$ ，而下一场中国队恰好输了。

再如，某型号火箭以往共发射3次，皆成功，按照统计量方法，成功率 $p$ 的95%置信下限为 $\sqrt[3]{1 - 0.95} \approx 0.368$ ，太低。而贝叶斯学派有“合理”方法提高。

还有对贝叶斯学派有利的例子，也有对其不利的例子。

- 涉及到哲学等，双方争论会长期存在（不同学科真理标准不同）。
- 实际应用中，各有利弊。
- 贝叶斯学派主要问题：能否/如何利用数据外知识。

## 第二节 什么是贝叶斯统计

### ● 基本问题：概率的定义。

频率学派定义为，某随机事件在多次重复后的“稳定”值，之后有“极限”，适合于掷硬币、物理试验等，不适合于天气预报、石油勘探等；

柯尔莫哥洛夫（A. H. Kolmogorov）的定义为公理化体系，可列可加性……，未从语义上真正定义何为概率，大家都同意；

贝叶斯学派定义为，对事件可能性的主观信任度，尤其适合于难以重复的事件，如“北京明天下雨的概率”、“某处下面有石油的概率”等，但可能不可重复，可能“不客观”。

硬币正面 $\frac{1}{2}$ 的概率，不再是硬币的属性，而是人大脑的主观产物。如果世界上有硬币，没有人，就没有概率。

## 第二节 什么是贝叶斯统计

对同一事件，不同的人可以有不同的主观（subjective）概率，如我掷硬币，对我，相关概率为1，对你……

对同一事件，同一个人也可以有不同的主观概率，随着你知识的累积、信息的更新……

博弈论的定义：你愿意付多高赌注，如巴西↔中国，你觉得1: 4公平，则你对巴西赢的主观概率为0.8 ( $1 \times 0.8 - 4 \times 0.2 = 0$ )。

所有概率都是条件概率，同一事件的概率不同是因为条件不同。

主观概率缺乏唯一性，一直是贝叶斯学派的一个大问题。

● 参数是未知的，故具有不确定性，因此就将其视为随机变量，故有（主观）概率分布。

其分布可以有多个，一般仅考虑两个：先验分布（得到数据前，prior）；后验分布（结合数据更新后，posterior）。-----end 20240527

## 第二节 什么是贝叶斯统计

对同一事件，不同的人可以有不同的主观（subjective）概率，如我掷硬币，对我，相关概率为1，对你……

对同一事件，同一个人也可以有不同的主观概率，随着你知识的累积、信息的更新……

博弈论的定义：你愿意付多高赌注，如巴西↔中国，你觉得1: 4公平，则你对巴西赢的主观概率为0.8 ( $1 \times 0.8 - 4 \times 0.2 = 0$ )。

所有概率都是条件概率，同一事件的概率不同是因为条件不同。

主观概率缺乏唯一性，一直是贝叶斯学派的一个大问题。

● 参数是未知的，故具有不确定性，因此就将其视为随机变量，故有（主观）概率分布。

其分布可以有多个，一般仅考虑两个：先验分布（得到数据前，prior）；后验分布（结合数据更新后，posterior）。

## 第二节 什么是贝叶斯统计

例1. 已知 $X \sim B(1, p)$ , 其中参数 $p$ 未知, 数据为 $x_1 = x_2 = x_3 = 1$ 。因为 $p$ 未知, 但 (主观) 知道 $0 \leq p \leq 1$ , 取其先验分布为 $U[0, 1]$ , 即

$$\pi(p) = I_{[0, 1]}(p)$$

此时, 似然函数为:

$$L(x_1, x_2, x_3 | p) = p^{\sum x_i} (1 - p)^{n - \sum x_i}$$

它是 (新解释) 给定参数 $p$ 时, 数据 $x_1, x_2, x_3$ 的条件分布密度。

因此, 所有随机变量 $(x_1, x_2, x_3, p)$ 的联合密度为:

$$f(x_1, x_2, x_3, p) = L(x_1, x_2, x_3 | p) \cdot \pi(p)$$

故当给定数据时,  $p$ 的条件分布密度为

$$\begin{aligned}\pi(p | x_1, \dots, x_n) &= \frac{L(x_1, \dots, x_n | p) \cdot \pi(p)}{\int_0^1 L(x_1, \dots, x_n | p) \cdot \pi(p) dp} \\ &= \frac{p^{\sum x_i} (1 - p)^{n - \sum x_i}}{\int_0^1 p^{\sum x_i} (1 - p)^{n - \sum x_i} dp} = \frac{p^{\sum x_i} (1 - p)^{n - \sum x_i}}{B_e(\sum x_i + 1, n - \sum x_i + 1)} \\ &= \frac{\Gamma(n + 2)}{\Gamma(\sum x_i + 1)\Gamma(n - \sum x_i + 1)} p^{\sum x_i} (1 - p)^{n - \sum x_i}\end{aligned}$$

## 第二节 什么是贝叶斯统计

其中 $B_e$ 为Beta函数。

称 $\pi(p|x_1, \dots, x_n)$ 为参数 $p$ 的后验分布密度。

贝叶斯统计的所有推断均来自后验分布。

对例1的数据， $\pi(p|x_1, x_2, x_3) = \frac{\Gamma(5)}{\Gamma(4)\Gamma(1)} p^3(1-p)^{3-3} = 4p^3$ ，其后验均值为

$$E_{posterior}p = \int_0^1 p \cdot 4p^3 dp = \dots = 4/5$$

这是对 $p$ 的（一个）点估计，注意频率学派为1。

## 第二节 什么是贝叶斯统计

- 若数据为恰三局两胜，则 $\sum x_i = 2$ ,

$$\pi(p|x_1, x_2, x_3) = \dots = 12p^2(1-p)$$

$$E_{posterior}p = \int_0^1 12p^3(1-p)dp = 12B_e(4, 2) = 12 \cdot \frac{3!}{5!} = \frac{3}{5}$$

- 若背景为投掷一枚（不均匀）硬币，则随着投掷次数 $n$ 增加，后验分布密度的图像会越来越高、窄，集中于“真值”。

数据 $x$ 与参数 $\theta$ 的联合密度有两种表达式：

$$f(x, \theta) = L(x|\theta)\pi(\theta) = \pi(\theta|x)h(x)$$

其中 $\pi(\theta)$ 、 $h(x)$ 分别为 $\theta$ 与 $x$ 的边缘密度， $L(x|\theta)$ 、 $\pi(\theta|x)$ 分别为条件密度。

作为 $\theta$ 的函数，后验分布密度 $\pi(\theta|x)$ 与先验密度 $\pi(\theta)$ 和似然函数 $L(x|\theta)$ 的乘积成正比，仅当需要求归一化因子时，才考虑 $h(x)$ 。

## 第二节 什么是贝叶斯统计

对 $\theta$ 的一切推断都通过后验分布 $\pi(\theta|x)$ 做出，如后验均值、后验方差、后验中位数、MAP (Mode) 等。

在较一般的条件下，有

$$\pi(\theta|x) = \frac{L(x|\theta)\pi(\theta)}{\int_{\Theta} L(x|\theta)\pi(\theta)d\theta}$$

例2. 设 $X \sim N(\theta, 1)$ ，数据为 $x_1, \dots, x_n$ ，若取参数 $\theta$ 的先验分布为 $\theta \sim N(0, \tau_0^2)$ ，求其后验分布。

解：

$$\begin{aligned} L(x|\theta)\pi(\theta) &= \left(\frac{1}{\sqrt{2\pi}}\right)^{n+1} \frac{1}{\tau_0} \exp\left\{-\frac{\theta^2}{2\tau_0^2} - \frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2\right\} \\ &\propto \exp\left\{-\frac{1}{2}\left(n + \frac{1}{\tau_0^2}\right)\left(\theta - \frac{\sum_{i=1}^n x_i}{n + 1/\tau_0^2}\right)^2\right\} \end{aligned}$$

## 第二节 什么是贝叶斯统计

故参数 $\theta$ 的后验分布为 $N\left(\frac{\sum_{i=1}^n x_i}{n+1/\tau_0^2}, \frac{1}{n+1/\tau_0^2}\right)$ 。

- 此例可一般化。先验分布方差 $\tau_0^2$ 大、小分别说明……
- 随着 $n$ 越来越大，后验方差趋于0，后验均值几乎就是 $\bar{x}$ ，先验分布的作用越来越小。

频率学派有置信区间（不易解释），贝叶斯学派有Bayes置信区间（Bayesian credible interval），方法及解释很直观：

当 $\pi(\theta|x)$ 形状较好（单峰）时，取区间 $[\theta_L, \theta_U]$ ，满足

$$\int_{\theta_L}^{\theta_U} \pi(\theta|x) d\theta = 1 - \alpha$$

（且 $\pi(\theta|x)$ 的值在区间内更大）。

## 第二节 什么是贝叶斯统计

实用中为方便起见，常取 $\theta_L$ 、 $\theta_U$ 满足

$$\int_{-\infty}^{\theta_L} \pi(\theta|x) d\theta = \int_{\theta_U}^{\infty} \pi(\theta|x) d\theta = \frac{\alpha}{2}$$

的简单方法。

对例2，参数 $\theta$ 的95%的贝叶斯置信区间为：

$$\left[ \frac{\sum_{i=1}^n x_i}{n + 1/\tau_0^2} - \frac{1.96}{\sqrt{n + 1/\tau_0^2}}, \frac{\sum_{i=1}^n x_i}{n + 1/\tau_0^2} + \frac{1.96}{\sqrt{n + 1/\tau_0^2}} \right]$$

- $n$ 越大，区间越窄，下降速度仍为 $1/\sqrt{n}$ 。对例1类似。
- 贝叶斯学派的一大优势是对置信区间简单易懂的解释：参数 $\theta$ 是随机变量，以 $1 - \alpha$ 的概率落在 $[\theta_L, \theta_U]$ 内。而频率学派对置信区间的解释较为曲折。

## 第二节 什么是贝叶斯统计

● Bayesian如何做预测（如对例2中 $x_{n+1}$ 的预测）？若参数 $\theta$ 已知，则直接利用 $x_{n+1}$ 的分布 $f(x_{n+1}|\theta)$ 。现 $\theta$ 的后验分布为 $\pi(\theta|x)$ ，综合 $\theta$ 的所有情况，得到 $x_{n+1}$ 的预测（预报）分布（predictive distribution）为

$$f(x_{n+1}|x_1, \dots, x_n) = \int_{\Theta} f(x_{n+1}|\theta) \cdot \pi(\theta|x_1, \dots, x_n) d\theta$$

如对例1，

$$P(x_4 = 1|x_1, x_2, x_3) = \int_0^1 p \cdot 4p^3 dp = \frac{4}{5}$$

恰为 $p$ 的贝叶斯点估计；对例2，经过较繁琐的推导，可以得到，

$$x_{n+1}|x_1, \dots, x_n \sim N\left(\frac{\sum_{i=1}^n x_i}{n + 1/\tau_0^2}, \frac{n + 1 + 1/\tau_0^2}{n + 1/\tau_0^2}\right)$$

预报分布是已知 $x_1, \dots, x_n$ 时， $x_{n+1}$ 的条件密度，恰符合由 $x_1, \dots, x_n$ 预报 $x_{n+1}$ 的直观解释。

## 第二节 什么是贝叶斯统计

- 贝叶斯学派对频率学派的又一优势：按频率学派理论 $x_1, \dots, x_n, x_{n+1}$ 相互独立同分布，故 $f(x_{n+1}|x_1, \dots, x_n) = f(x_{n+1})$ ，即不能利用 $x_1, \dots, x_n$ 预测 $x_{n+1}$ ！

贝叶斯学派的解释为：当给定参数 $\theta$ 时， $x_1, \dots, x_n, x_{n+1}$ 相互独立（条件独立性）。

由于 $\theta$ 是随机变量，故当需要比较 $\theta$ 的两个函数时，可以通过求期望（加权平均）化为对两个数的比较。故在决策论中有：

定义1. 设 $\theta$ 的先验分布为 $\pi(\theta)$ ， $\delta$ 是一个（统计）决策，记

$$\rho(\delta) = E_\pi R(\theta, \delta) = \int_{\Theta} R(\theta, \delta) \pi(\theta) d\theta$$

称为 $\delta$ 的平均风险。

- 每个决策对应于唯一的一个数值，故不同的决策可比较。

## 第二节 什么是贝叶斯统计

定义2. 若决策 $\delta^*$ 使得平均风险达到最小，即

$$\rho(\delta^*) = \inf\{\rho(\delta), \forall \delta\}$$

则称 $\delta^*$ 为贝叶斯决策。

贝叶斯决策的思想：损失函数为 $L(\theta, \delta(X))$ ，先对 $X$ 求平均，得风险函数 $R(\theta, \delta)$ ，再对 $\theta$ 求平均，得平均风险 $\rho(\delta)$ 。 $\delta^*$ 是综合所有随机因素后，平均风险（损失）最小的决策。

对于本节例1、例2，若取损失函数为平方损失，则贝叶斯决策（贝叶斯估计）恰为其后验均值。

例3（第一节例3）如果取先验分布为 $\pi(\theta_1) = 0.7, \pi(\theta_2) = 0.3$ ，则平均风险可计算，结果列表如下：

|                | $\delta_1$ | $\delta_2$ | $\delta_3$ | $\delta_4$ | $\delta_5$ | $\delta_6$ | $\delta_7$ | $\delta_8$ | $\delta_9$ |
|----------------|------------|------------|------------|------------|------------|------------|------------|------------|------------|
| $\rho(\delta)$ | 3.6        | 7.18       | 5.33       | 3.72       | 7.3        | 5.45       | 3.57       | 7.15       | 5.3        |

故而， $\delta_7$ 是贝叶斯决策（发烫则修理，不发烫则保留）。

## 第二节 什么是贝叶斯统计

一般情况下，可能的决策太多，无法穷举，如何求贝叶斯决策？

$\rho(\delta)$ 是通过两次积分得到的，故交换积分次序得：

$$\begin{aligned}\rho(\delta) &= \int_{\Theta} \left[ \int_X L(\theta, \delta(x)) p(x|\theta) dx \right] \cdot \pi(\theta) d\theta \\ &= \int_X \left[ \int_{\Theta} L(\theta, \delta(x)) \pi(\theta|x) d\theta \right] \cdot h(x) dx\end{aligned}$$

故而，当得到数据 $x$ 后，只需在行动空间 $A$ 中找 $a_x$ ，使得

$$\int_{\Theta} L(\theta, \delta(x)) \pi(\theta|x) d\theta$$

达到最小即可（不再考虑对 $x$ 的积分），即 $\delta^*(x) = a_x$ 。

- 贝叶斯学派的又一观点：决策只与后验分布有关，而后验分布 $\pi(\theta|x)$ 只与观测到的数据 $x$ 有关！即不必考虑 $x$ 未取到的可能数据的情形。

## 第二节 什么是贝叶斯统计

例4. 设 $X \sim N(\mu, 1)$ ,  $\mu \in \Theta = \{0, 2\}$ ,  $H_0: \mu = 0 \leftrightarrow H_1: \mu = 2$ , 损失函数为:

$$L(\mu, a_0) = \begin{cases} 0 & \text{当 } \mu = 0 \\ 1 & \text{否则} \end{cases}, \quad L(\mu, a_1) = \begin{cases} 1 & \text{当 } \mu = 0 \\ 0 & \text{否则} \end{cases}$$

其中 $l_1 = l_2 = 1$ 为已知常数(0-1损失), 若 $\mu$ 的先验分布为 $\pi(0) = 1 - \pi(2) = p_0 = 0.5$ , 数据为简单随机样本 $x_1, \dots, x_n$ , 求问题的贝叶斯检验(贝叶斯决策), 及两类错误的概率。

解: 由前面知识,

$$L(x|\mu) = \left( \frac{1}{\sqrt{2\pi}} \right)^n e^{-\frac{1}{2}\sum_{i=1}^n (x_i - \mu)^2} \propto e^{-\frac{n}{2}(\bar{x} - \mu)^2}$$

所以,

$$\begin{aligned} \pi(0|x) &= 0.5C_0 e^{-\frac{n}{2}\bar{x}^2} \\ \pi(2|x) &= 0.5C_0 e^{-\frac{n}{2}(\bar{x} - 2)^2} \end{aligned}$$

其中 $C_0$ 为某归一化常数。因此,

## 第二节 什么是贝叶斯统计

$$\begin{aligned}\rho(\delta) &= \int_{\Theta} L(\mu, \delta(x)) \pi(\mu|x) d\mu \\ &= 0.5C_0 e^{-\frac{n}{2}\bar{x}^2} L(0, \delta(x)) + 0.5C_0 e^{-\frac{n}{2}(\bar{x}-2)^2} L(2, \delta(x)) \\ &\propto I\{\text{否定 } H_0\} + e^{2n\bar{x}-2n} I\{\text{不否定 } H_0\}\end{aligned}$$

故贝叶斯解为：

$$\varphi(x) = \begin{cases} 1 & \text{当 } \bar{x} > 1 \\ 0 & \text{否则} \end{cases}$$

两类错误的概率为：

$$\alpha = P(\bar{x} > 1 | \mu = 0) = \dots = 1 - \Phi(\sqrt{n})$$

$$\beta = P(\bar{x} \leq 1 | \mu = 2) = \dots = 1 - \Phi(-\sqrt{n})$$

- 当  $p_0 \neq 0.5$  或两类错误的损失不同时，检验法不必以1为临界值，两类错误的概率亦可不同。

### 第三节 关于先验分布



首先，一些人不接受“主观概率”的定义，因此也不接受“先验分布”、“后验分布”及其它贝叶斯统计的概念和方法。此争议会长期存在。概率论中，选山羊或选汽车的例子就用到了先验分布。

其次，贝叶斯统计（以往）存在计算上的困难：后验分布正比于似然函数与先验分布的乘积，但归一化因子、后验均值、后验方差等的计算均归结于（高维）积分。近年来快速发展并得到广泛应用的马尔科夫链随机模拟（Markov chain Monte Carlo，简记为MCMC）方法可较好地解决此问题。当然，仍可能有计算速度、收敛性等问题。

再次，在同意使用贝叶斯统计方法的前提下，如何构造、确定先验分布，是最易引起争议的问题！先验知识往往较模糊，不同的人先验知识也不同。

---

下面几条非并列关系。

# 第三节 关于先验分布

## 一、经验贝叶斯方法

由数据（历史数据或现时数据）构造先验分布。例如，先选定先验分布的类型，再根据数据得到（估计）其（超）参数。可以看作贝叶斯学派与频率学派的结合。优点是相对客观；不足是当无历史数据时，现时数据（可能）两次被使用。

## 二、“同等无知”

若参数 $\theta$ 仅取有限个点，则先验分布取为离散型均匀分布；若参数 $\theta \in [a, b]$ ，则取先验分布为 $U[a, b]$ ；若参数 $\theta \in (-\infty, \infty)$ ，取 $\pi(\theta) = c > 0$ （广义先验分布？Improper prior），后验分布往往是proper distribution，例如第二节中的例2，后验分布为 $N(\bar{x}, \frac{1}{n})$ 。

问题：此先验分布对参数变换不具不变性，例如，参数 $\theta$ 是圆盘半径，若设其服从均匀分布，则圆盘面积 $\pi\theta^2$ （亦可设为参数）不服从均匀分布。

## 第三节 关于先验分布

### 三、无信息先验分布等

无信息先验分布 (Non-informative prior)

非主观先验分布 (Non-subjective prior)

即希望先验分布不包含关于参数 $\theta$ 的任何信息。其想法容易理解、接受，但具体实施有不少问题。

Jeffreys (1961) 提出使用 $\theta$ 的Fisher信息量的平方根来定义其先验分布，（当 $\theta$ 是多维参数时，可使用其Fisher信息矩阵行列式的平方根），并“论证”了它是无信息的，称为Jeffreys原则。

对于多种多样的统计模型，无信息先验分布中的“无信息”界定较复杂，且其结果往往也不唯一。但一般地，各种无信息先验分布确实对后验分布的影响很小。

## 第三节 关于先验分布



### 四、共轭分布族

如果先验分布 $\pi(\theta)$ 的类型使得后验分布 $\pi(\theta|x)$ 仍为此类型，则称先验分布 $\pi(\theta)$ 是密度函数 $f(x|\theta)$ 的共轭分布。

优点：推导、计算非常方便。不足：仍有未知超参数；有的共轭分布不足以描述各种先验知识。

定理1. 设 $X_1, \dots, X_n$ 是来自两点分布 $B(1, p)$ 的简单随机样本，若取参数 $p$ 的先验分布为 $Be(\alpha, \beta)$ ，其中 $\alpha > 0, \beta > 0$ 为超参数，则 $p$ 的后验分布为 $Be(\alpha + \sum_{i=1}^n X_i, \beta + n - \sum_{i=1}^n X_i)$ 。

证明：略（第二节例1的推广。由此，贝塔分布是两点分布的共轭分布）。

$Be(\alpha, \beta)$ 的图像可为……， $Be(1, 1)$ 即为 $U[0, 1]$ 。

### 第三节 关于先验分布

定理2. 设 $X_1, \dots, X_n$ 是来自参数为 $\lambda$ 的Poisson分布的简单随机样本，若取 $\lambda$ 的先验分布为 $\Gamma(\alpha, \beta)$ ，其中 $\alpha > 0, \beta > 0$ 为超参数，则 $\lambda$ 的后验分布为 $\Gamma(\alpha + \sum_{i=1}^n X_i, \beta + n)$ 。

证明：

$$\pi(\lambda) = C\lambda^{\alpha-1}e^{-\beta\lambda}$$
$$L(X_1, \dots, X_n | \lambda) = \prod_{i=1}^n \frac{\lambda^{X_i}}{X_i!} e^{-\lambda} = \frac{\lambda^{\sum_{i=1}^n X_i}}{X_1! \cdots X_n!} e^{-n\lambda}$$

故

$$\pi(\lambda | X_1, \dots, X_n) \propto \pi(\lambda)L(X_1, \dots, X_n | \lambda) \propto C' \lambda^{\alpha+\sum_{i=1}^n X_i-1} e^{-(\beta+n)\lambda}$$

证毕。（由此，伽马分布是Poisson分布的共轭分布）。

定理3. 设 $X_1, \dots, X_n$ 是来自指数分布 $\lambda e^{-\lambda x}$ 的简单随机样本，若取参数 $\lambda$ 的先验分布为 $\Gamma(\alpha, \beta)$ ，其中 $\alpha > 0, \beta > 0$ 为超参数，则 $\lambda$ 的后验分布为 $\Gamma(\alpha + n, \beta + \sum_{i=1}^n X_i)$ 。

### 第三节 关于先验分布

证明：

$$\pi(\lambda) = C\lambda^{\alpha-1}e^{-\beta\lambda}$$
$$L(X_1, \dots, X_n | \lambda) = \prod_{i=1}^n \lambda e^{-\lambda X_i} = \lambda^n e^{-\lambda \sum_{i=1}^n X_i}$$

故

$$\pi(\lambda | X_1, \dots, X_n) \propto \pi(\lambda) L(X_1, \dots, X_n | \lambda) \propto C' \lambda^{\alpha+n-1} e^{-(\beta + \sum_{i=1}^n X_i)\lambda}$$

证毕。（由此，伽马分布是指数分布的共轭分布）

定理4. 设 $X_1, \dots, X_n$ 是来自正态分布 $N(\mu, \sigma_0^2)$ 的简单随机样本，其中 $\sigma_0^2$ 已知，若取参数 $\mu$ 的先验分布为 $N(\mu_0, \tau_0^2)$ ，则 $\mu$ 的后验分布为 $N(\mu^*, (\sigma^*)^2)$ ，其中

$$\mu^* = \frac{\mu_0 \sigma_0^2 + n \tau_0^2 \bar{X}}{\sigma_0^2 + n \tau_0^2}$$
$$(\sigma^*)^2 = \frac{\sigma_0^2 \tau_0^2}{\sigma_0^2 + n \tau_0^2}$$

证明：略（第二章例2的推广）

### 第三节 关于先验分布

定义1. 称随机变量 $Y$ 服从参数为 $\alpha$ 、 $\beta$ 的逆（倒） $\Gamma$ 分布，记为 $Y \sim IG(\alpha, \beta)$ ，若

$$1/Y \sim \Gamma(\alpha, \beta) \quad (\alpha > 0, \beta > 0) .$$

定理5. 设 $X_1, \dots, X_n$ 是来自正态分布 $N(\mu_0, \sigma^2)$ 的简单随机样本，其中 $\mu_0$ 已知，若取参数 $\sigma^2$ 的先验分布为 $IG(\alpha, \beta)$ ，则 $\sigma^2$ 的后验分布为 $IG(\alpha + \frac{n}{2}, \beta + \frac{1}{2} \sum_{i=1}^n (X_i - \mu_0)^2)$ 。

证明：利用概率论知识，易知 $IG(\alpha, \beta)$ 的密度函数为

$$g(t) = \frac{\beta^\alpha}{\Gamma(\alpha)} t^{-\alpha-1} e^{-\frac{\beta}{t}} \quad (t > 0)$$

记 $T = \sigma^2$ ，则其先验分布密度为

$$\pi(t) = \frac{\beta^\alpha}{\Gamma(\alpha)} t^{-\alpha-1} e^{-\frac{\beta}{t}}$$

### 第三节 关于先验分布

似然函数为

$$L(X_1, \dots, X_n | t) = Ct^{-\frac{n}{2}}e^{-\frac{1}{2t}\sum_{i=1}^n (X_i - \mu_0)^2},$$

其中  $C$  (及后面  $C'$ ) 为常数。故而，

$$\pi(t | X_1, \dots, X_n) \propto \pi(t)L(X_1, \dots, X_n | t) \propto C't^{-\left(\alpha + \frac{n}{2}\right)-1}e^{-\frac{1}{t}[\beta + \frac{1}{2}\sum_{i=1}^n (X_i - \mu_0)^2]}$$

证毕。

● 在利用贝叶斯方法处理  $\mu$ 、 $\sigma^2$  均未知的正态模型时，我们引入下面的定义。

定义2. 称二维随机向量  $(M, R)$  服从参数为  $(\mu, \tau, \alpha, \beta)$  的正态-  $\Gamma$  先验分布，若  $R$  的边缘分布是参数为  $\alpha, \beta$  的  $\Gamma$  分布，而在  $R = r$  下  $M$  的条件分布是  $N(\mu, \frac{1}{\tau r})$ 。这时  $(M, R)$  的分布密度为

$$\varphi(m, r; \mu, \tau, \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \sqrt{\tau} r^{\alpha - \frac{1}{2}} \exp \left\{ -\frac{\tau r}{2} (m - \mu)^2 - \beta r \right\}$$

### 第三节 关于先验分布

定理6. 设 $X_1, \dots, X_n$ 是来自正态分布 $N(M, \frac{1}{R})$ 的简单随机样本， $M, R$ 未知。设 $(M, R)$ 的先验分布是参数为 $(\mu, \tau, \alpha, \beta)$ 的正态- $\Gamma$ 分布，则在 $X_1 = x_1, \dots, X_n = x_n$ 下， $(M, R)$ 的后验分布是参数为 $(\mu^*, \tau^*, \alpha^*, \beta^*)$ 的正态- $\Gamma$ 分布，其中

$$\begin{aligned}\mu^* &= \frac{\tau\mu + n\bar{x}}{\tau + n}, & \tau^* &= \tau + n, & \alpha^* &= \alpha + \frac{n}{2}, \\ \beta^* &= \beta + \frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})^2 + \frac{\tau n(\bar{x} - \mu)^2}{2(n-1)} & (\bar{x} &= \frac{1}{n} \sum_{i=1}^n x_i)\end{aligned}$$

证明： $X_1, \dots, X_n$ 的联合密度为

$$f_n(x_1, \dots, x_n) = \left(\frac{r}{2\pi}\right)^{\frac{n}{2}} \exp\left\{-\frac{r}{2} \sum_{i=1}^n (x_i - m)^2\right\}$$

$(M, R)$ 的先验分布密度由定义2所示，因此知 $(M, R)$ 的后验分布密度

$$\pi(m, r | x_1, \dots, x_n) \propto r^{\alpha + \frac{n-1}{2}} \exp\left\{-\frac{r}{2} [\sum_{i=1}^n (x_i - m)^2 + \tau(m - \mu)^2] - \beta r\right\}$$

### 第三节 关于先验分布

由于

$$\begin{aligned} \sum_{i=1}^n (x_i - m)^2 + \tau(m - \mu)^2 &= \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} \\ &\quad - m)^2 + \tau(m - \mu)^2 \\ &= \sum_{i=1}^n (x_i - \bar{x})^2 + (\tau + n) \left( m - \frac{n\bar{x} + \tau\mu}{\tau + n} \right)^2 + \frac{n\tau(\bar{x} - \mu)^2}{\tau + n} \end{aligned}$$

因此

$$\begin{aligned} \pi(m, r | x_1, \dots, x_n) &\propto r^{\alpha + \frac{n-1}{2}} \exp \left\{ -\frac{\tau + n}{2} r(m - \mu^*)^2 - \beta r \right\} \\ &= \varphi(m, r; \mu^*, \tau^*, \alpha^*, \beta^*), \end{aligned}$$

即后验分布是参数为  $(\mu^*, \tau^*, \alpha^*, \beta^*)$  的正态- $\Gamma$ 分布，证毕。

----- end 20240530

定义3. 称随机变量  $X$  服从参数为  $x_0 > 0, \alpha > 0$  的Pareto分布，若其密度函数为

$$h(x) = \begin{cases} \alpha x_0^\alpha x^{-\alpha-1} & \text{当 } x \geq x_0 \\ 0 & \text{否则} \end{cases}$$

### 第三节 关于先验分布

由于

$$\begin{aligned} \sum_{i=1}^n (x_i - m)^2 + \tau(m - \mu)^2 &= \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} \\ &\quad - m)^2 + \tau(m - \mu)^2 \\ &= \sum_{i=1}^n (x_i - \bar{x})^2 + (\tau + n) \left( m - \frac{n\bar{x} + \tau\mu}{\tau + n} \right)^2 + \frac{n\tau(\bar{x} - \mu)^2}{\tau + n} \end{aligned}$$

因此

$$\begin{aligned} \pi(m, r | x_1, \dots, x_n) &\propto r^{\alpha + \frac{n-1}{2}} \exp \left\{ -\frac{\tau + n}{2} r(m - \mu^*)^2 - \beta r \right\} \\ &= \varphi(m, r; \mu^*, \tau^*, \alpha^*, \beta^*), \end{aligned}$$

即后验分布是参数为  $(\mu^*, \tau^*, \alpha^*, \beta^*)$  的正态- $\Gamma$ 分布，证毕。

定义3. 称随机变量  $X$  服从参数为  $x_0 > 0, \alpha > 0$  的Pareto分布，若其密度函数为

$$h(x) = \begin{cases} \alpha x_0^\alpha x^{-\alpha-1} & \text{当 } x \geq x_0 \\ 0 & \text{否则} \end{cases}$$

### 第三节 关于先验分布

定理6. 设 $X_1, \dots, X_n$ 是来自均匀分布 $U[0, \theta]$ 的简单随机样本，若取参数 $\theta$ 的先验分布为超参数 $\theta_0, \alpha$ 的Pareto分布，则 $\theta$ 的后验分布是超参数为 $\theta'_0, \alpha + n$ 的Pareto分布，其中 $\theta'_0 = \max\{\theta_0, X_1, \dots, X_n\}$ 。

- 超参数 $\alpha$ 的大小表示对 $\theta$ 靠近 $\theta_0$ （右侧）主观信念的强弱：越大越强，越小先验密度越平。

证明： $\theta$ 的先验密度为

$$\pi(\theta) = \frac{\alpha \theta_0^\alpha}{\theta^{\alpha+1}} I_{[\theta_0, \infty)}(\theta)$$

似然函数为

$$\begin{aligned} L(X_1, \dots, X_n | \theta) &= \frac{1}{\theta^n} \prod_{i=1}^n I_{[0, \theta]}(X_i) = \frac{1}{\theta^n} I_{[0, \theta]}(\max X_i) \\ &= \frac{1}{\theta^n} I_{[\max X_i, \infty)}(\theta) \end{aligned}$$

### 第三节 关于先验分布

故而，

$$\pi(\theta|X_1, \dots, X_n) \propto \pi(\theta)L(X_1, \dots, X_n|\theta) \propto \frac{1}{\theta^{\alpha+n+1}} I_{[\theta'_0, \infty)}(\theta)$$

证毕。

定义4. 称 $(Y_1, Y_2)$ 服从参数为 $(r_1, r_2, \alpha)$ 的二维Pareto分布( $r_1 < r_2$ , 且 $\alpha > 0$ )，若其分布密度函数是

$$g(y_1, y_2; r_1, r_2, \alpha) = \frac{\alpha(\alpha + 1)(r_2 - r_1)^\alpha}{(y_2 - y_1)^{\alpha+2}} I_{(-\infty, r_1]}(y_1) I_{[r_2, \infty)}(y_2).$$

定理3.8 设 $X_1, \dots, X_n$ 是来自 $[\theta_1, \theta_2]$ 上均匀分布的样本， $\theta_1 < \theta_2$ 未知。设 $(\theta_1, \theta_2)$ 的先验分布是参数为 $r_1, r_2, \alpha$ 的二维Pareto分布，则在 $X_1 = x_1, \dots, X_n = x_n$ 下， $(\theta_1, \theta_2)$ 的后验分布是参数为 $r_1^*, r_2^*, \alpha^*$ 的二维Pareto分布，其中 $r_1^* = \min\{r_1, X_1, \dots, X_n\}$ ,  $r_2^* = \max\{r_2, X_1, \dots, X_n\}$ ,  $\alpha^* = \alpha + n$ 。

### 第三节 关于先验分布

证明： $X_1, \dots, X_n$ 的联合密度为

$$\begin{aligned} f(x_1, \dots, x_n; \theta_1, \theta_2) &= \prod_{i=1}^n \frac{1}{\theta_2 - \theta_1} I_{[\theta_1, \theta_2]}(x_i) \\ &= \frac{1}{(\theta_2 - \theta_1)^n} I_{[\theta_1, \infty)}(\min x_i) \cdot I_{(-\infty, \theta_2]}(\max x_i) \end{aligned}$$

$(\theta_1, \theta_2)$ 的先验密度由定义4给出，因此 $(\theta_1, \theta_2)$ 的后验密度为

$$\begin{aligned} &\xi(\theta_1, \theta_2 | x_1, \dots, x_n) \\ &= \frac{\alpha(\alpha+1)(r_2 - r_1)^\alpha}{(\theta_2 - \theta_1)^{\alpha+n+2}} I_{(-\infty, r_1]}(\theta_1) I_{[r_2, \infty)}(\theta_2) I_{[\theta_1, \infty)}(\min x_i) I_{(-\infty, \theta_2]}(\max x_i) \\ &= \frac{C}{(\theta_2 - \theta_1)^{\alpha+n+2}} I_{(-\infty, r_1^*]}(\theta_1) I_{[r_2^*, \infty)}(\theta_2) = g(\theta_1, \theta_2, r_1^*, r_2^*, \alpha^*), \end{aligned}$$

因此后验分布是参数为 $(r_1^*, r_2^*, \alpha^*)$ 的Pareto分布，证毕。

教材中给出了较一般情形下利用充分统计量寻找共轭分布的方法，有兴趣的可查阅。

### 第三节 关于先验分布

#### 四、层次贝叶斯学派 (Hierarchical Bayesian)

前面已有涉及：设参数 $\theta$ 服从某种带有超参数 $\alpha$ 的分布， $\alpha$ 待定，而超参数 $\alpha$ 又服从某个或某种分布（若某种，还可分层）。

例如， $X_1, \dots, X_n | p \sim B(1, p)$ ,  $p | \alpha, \beta \sim Be(\alpha, \beta)$ , 而 $\alpha \sim Exp(\lambda_1)$ ,  $\beta \sim Exp(\lambda_2)$ 。其图示为……

优点：先验分布不再是一个分布，而是一（大）类分布。利于描述多种先验知识；先验分布更“平”。适用于MCMC计算。

- 还有最大熵先验分布等，主要思想是构造尽可能不包含任何信息的先验分布。

### 第三节 关于先验分布



#### 五、关于“主观”的讨论

自然科学的一般标准要求研究者应该是客观的。

一般初学者容易认为，贝叶斯学派主观，频率学派客观。

一些贝叶斯学派的研究者极力构造“客观”的先验分布。

统计分析中，主观性难以避免：模型的选择不同、优良性标准的不同、置信度、检验水平、分段数目、核函数的选择不同、假设的不同，到本章参数空间、损失函数等的定义不同，都不可避免地带有主观性。

较激烈的Bayesian说：他们将主观摆在桌面上，而频率学派将主观藏在桌面下，只拿出客观的东西来标榜自己。

### 第三节 关于先验分布



当数据量较大时，只要模型一样（似然函数相同），则频率学派和贝叶斯学派的结果很近似（后验=先验+似然）。

大多数情况下，应取较“平”的先验分布，并/或说明，先验分布的选取对分析结果影响不大。

如果先验分布的选取确实较显著地影响后验分布，则必须对先验分布选取的理由给出解释（如相关领域专家坚持）。

## 第四节 马氏链随机模拟

### 一、目的

近几十年统计学最主要的进展之一，极大促进了贝叶斯统计的发展，和各种复杂模型的应用。

贝叶斯统计的主要推断思路：后验分布正比于先验分布与似然函数的乘积。但求后验分布需要求积分，求后验均值等也同样。

当参数空间维数较高、或乘积函数形式较复杂时，积分可能无法进行。

马尔科夫链随机模拟（Markov chain Monte Carlo）可以解决此问题。需要大量的计算。

基本思路：利用随机模拟方法，通过分步抽样，构造一个适当的马氏链，得到近似的、相依的后验分布模拟样本，并通过此样本计算后验的特征，如均值、分位数等。

## 第四节 马氏链随机模拟



分步的作用在于将复杂问题简单化。

记 $\pi(\theta) = \pi(\theta_1, \dots, \theta_n)$ 为先验分布与似然函数的乘积（数据已给定，不再显式表示，同时 $n$ 不再表示样本量，而表示参数个数）， $\theta = (\theta_1, \dots, \theta_n) \in \Theta \subset R^n$ 为模型参数，模拟出的马氏链为 $(\theta^{(1)}, \dots, \theta^{(m)}, \dots)$ 。

在一定条件下（马氏链是非周期的，不可约的），由遍历性有

$$\frac{1}{m} \sum_{k=1}^m f(\theta^{(k)}) \rightarrow E_{posterior}[f(\theta)]$$

其中 $f(\theta)$ 为参数 $\theta$ 的 $n$ 元实值函数（数学要求不高），故可以适当选择来计算如 $\theta_1$ 的均值、方差等。还有，当 $m$ 较大时， $\theta^{(m)}$ 可近似地看成后验分布的一个样本。独立重复可得多个样本。

### 二、Gibbs sampler

## 第四节 马氏链随机模拟

记 $\pi(\theta_i|\theta_{-i})$ 为给定 $\theta$ 的所有其他分量 $\theta_{-i} = (\theta_1, \dots, \theta_{i-1}, \theta_{i+1}, \dots, \theta_n)$ 时， $\theta_i$ 的条件分布密度。一般 $\pi(\theta)$ 的形式可能很复杂（多元函数），但 $\pi(\theta_i|\theta_{-i})$ 往往较简单（一元函数），可由 $\pi(\theta)$ 的形式得到（或正比于）。

一般算法如下：

- ① 产生起始点 $\theta^{(0)} = (\theta_1^{(0)}, \dots, \theta_n^{(0)})$ （如从 $\theta$ 的先验分布模拟抽样）；
- ② 从 $\pi(\theta_1|\theta_2^{(0)}, \theta_3^{(0)}, \dots, \theta_n^{(0)})$ 中模拟产生 $\theta_1^{(1)}$ ；
- ③ 从 $\pi(\theta_2|\theta_1^{(1)}, \theta_3^{(0)}, \dots, \theta_n^{(0)})$ 中模拟产生 $\theta_2^{(1)}$ ；
- ④ 从 $\pi(\theta_3|\theta_1^{(1)}, \theta_2^{(1)}, \theta_4^{(0)}, \dots, \theta_n^{(0)})$ 中模拟产生 $\theta_3^{(1)}$ ；
- ⑤ .....
- ⑥ 从 $\pi(\theta_n|\theta_1^{(1)}, \dots, \theta_{n-1}^{(1)})$ 中模拟产生 $\theta_n^{(1)}$ 。

## 第四节 马氏链随机模拟

如此完成从 $\theta^{(0)}$ 到 $\theta^{(1)}$ 的更新。反复重复以上②至⑥，得到马氏链 $(\theta^{(1)}, \dots, \theta^{(m)}, \dots)$ 。

此过程之所以是马氏的，是因为任何一个参数的更新，只依赖于其他参数的当前值。任一个参数一旦被更新，其原值就（可以被存储）不再影响程序运行。

此马氏链每一步的转移概率为：

$$K(\theta^{(m)}, \theta^{(m+1)}) = \prod_{i=1}^n \pi(\theta_i^{(m+1)} | \theta_1^{(m+1)}, \dots, \theta_{i-1}^{(m+1)}, \theta_{i+1}^{(m)}, \dots, \theta_n^{(m)})$$

$\theta$ 的各分量的次序可以充分考虑计算方便。

不必一次仅更新一个分量（有时，同时更新多个更快，或更方便）。

## 第四节 马氏链随机模拟

### 三、Metropolis-Hastings算法

当Gibbs sampler的某些步骤难以直接实现时（即无法直接产生某种分布的随机数），可采用Metropolis-Hastings算法。一般地叙述如下：

设 $q(\theta, \theta')$ 为（任意的）转移概率函数，希望从 $\theta^{(m)}$ 转移到 $\theta^{(m+1)}$ （可能仅变化一个分量），先由 $q(\theta^{(m)}, \theta')$ 产生一个候选 $\theta'$ ，之后计算 Hastings ratio  $r(\theta^{(m)}, \theta')$ ，再后以概率 $r(\theta^{(m)}, \theta')$ 接受 $\theta^{(m+1)} = \theta'$ ，以概率 $1 - r(\theta^{(m)}, \theta')$ 停留在 $\theta^{(m+1)} = \theta^{(m)}$ 。

$$r(\theta^{(m)}, \theta') = \begin{cases} \min \left\{ \frac{\pi(\theta') q(\theta', \theta^{(m)})}{\pi(\theta^{(m)}) q(\theta^{(m)}, \theta')}, 1 \right\} & \text{若 } \pi(\theta^{(m)}) q(\theta^{(m)}, \theta') > 0 \\ 1 & \text{若 } \pi(\theta^{(m)}) q(\theta^{(m)}, \theta') = 0 \end{cases}$$

如此产生的马氏链的转移概率为：

## 第四节 马氏链随机模拟


$$p(\theta^{(m)}, \theta') = \begin{cases} q(\theta^{(m)}, \theta') r(\theta^{(m)}, \theta') & \text{若 } \theta' \neq \theta^{(m)} \\ 1 - \sum_{\theta} q(\theta^{(m)}, \theta) r(\theta^{(m)}, \theta) & \text{若 } \theta' = \theta^{(m)} \end{cases}$$

可以验证，

$$\pi(\theta^{(m)}) p(\theta^{(m)}, \theta') = \pi(\theta') p(\theta', \theta^{(m)})$$

这是马氏链以相应后验分布为平稳分布的一个重要条件。

实际应用中， $\theta^{(m)} \rightarrow \theta^{(m+1)}$ 常常仅更新一个分量，合理选择 $q(\theta, \theta')$ （如先验分布），可以使得 $r(\theta^{(m)}, \theta')$ 的计算简单。

此算法包含Gibbs sampler：当取 $q(\theta, \theta') = \pi(\theta_i | \theta_{-i})$ 时 ( $\theta' = \theta^{(m+1)}$ )，

$$\frac{\pi(\theta') q(\theta', \theta^{(m)})}{\pi(\theta^{(m)}) q(\theta^{(m)}, \theta')} = 1$$

即 $r(\theta, \theta') \equiv 1$ ，总是接受候选。

## 第四节 马氏链随机模拟



- 常见方式：当可以从 $\pi(\theta_i | \theta_{-i})$ 直接抽样时，用Gibbs sampler；否则，用Metropolis-Hastings算法。

### 四、估计方法

- 因为起始点 $\theta^{(0)}$ 可能受主观因素（先验分布）影响，往往选择（大整数） $M$ ，当 $m < M$ 时， $\theta^{(m)}$ 不被使用。
- $(\theta^{(1)}, \dots, \theta^{(m)}, \dots)$ 是马氏链，不是独立随机样本，故当其相关性较强时，会采取每隔若干次循环，记忆一个样本的方式。
- 抽样样本质量监控：某些参数图像、似然函数图像、……
- 后验均值、后验方差、后验中位数、后验Mode、贝叶斯置信区间等：直接由模拟样本得到。

## 第四节 马氏链随机模拟



- 独立产生若干个链，得到近似*i. i. d.*的样本。
- 主要成果：使得从前无法解决的问题得以解决；产生了大量新的模型；算法研究（收敛速度、模型选择等）有了极大进展；大数据研究方面有用武之地；大大推进了统计学的应用。
- 主要缺点：计算时间长，有时不收敛。
- 不完全数据的处理：将当前参数值 $\theta^{(m)}$ 当作真值，从缺失数据的条件分布中产生其模拟值；将此模拟值当作真数据，用全体数据及模型更新 $\theta^{(m)}$ 到 $\theta^{(m+1)}$ 。
- 无论哪种方法，总有“反例”说明其不好。

## 第四节 马氏链随机模拟



例1. 设 $X_1, \dots, X_n | p \sim B(1, p)$ ,  $p | \alpha, \beta \sim Be(\alpha, \beta)$ ,  $\alpha \sim Exp(\lambda_1)$ ,  $\beta \sim Exp(\lambda_2)$ , 其中参数为 $p$ 、 $\alpha$ 和 $\beta$ ,  $\lambda_1$ 和 $\lambda_2$ 为已知超参数, 求MCMC算法。

解: 层次贝叶斯图示为……。

参数 $\theta$ 的先验分布为

$$\pi(\theta) = C p^{\alpha-1} (1-p)^{\beta-1} e^{-\lambda_1 \alpha} e^{-\lambda_2 \beta}$$

所以,

$$\begin{aligned}\pi(\theta | X) &\propto p^{\alpha-1} (1-p)^{\beta-1} e^{-\lambda_1 \alpha} e^{-\lambda_2 \beta} p^{\sum X_i} (1-p)^{n-\sum X_i} \\ &= p^{\alpha+\sum X_i-1} (1-p)^{\beta+n-\sum X_i-1} e^{-\lambda_1 \alpha} e^{-\lambda_2 \beta}\end{aligned}$$

故而,

## 第四节 马氏链随机模拟

$$\pi(p|X, \alpha, \beta) \sim Be\left(\alpha + \sum X_i, \beta + n - \sum X_i\right)$$

$$\begin{aligned}\pi(\alpha|X, p, \beta) &\propto e^{(\alpha + \sum X_i - 1)\log(p) - \lambda_1 \alpha} \\ &\sim Exp(\lambda_1 - \log(p))\end{aligned}$$

$$\begin{aligned}\pi(\beta|X, p, \alpha) &\propto e^{(\beta + n - \sum X_i - 1)\log(1-p) - \lambda_2 \beta} \\ &\sim Exp(\lambda_2 - \log(1-p))\end{aligned}$$

因此，例1中的MCMC具体算法（之一）为：

## 第四节 马氏链随机模拟

- 
- ① 产生起始点  $\theta^{(0)} = (\alpha^{(0)}, \beta^{(0)}, p^{(0)})$ , 其中  $\alpha^{(0)} \sim Exp(\lambda_1)$ ,  
 $\beta^{(0)} \sim Exp(\lambda_2)$ ,  $p^{(0)} \sim Be(\alpha^{(0)}, \beta^{(0)})$  ;
  - ② 从  $Be(\alpha^{(0)} + \sum X_i, \beta^{(0)} + n - \sum X_i)$  中模拟产生  $p^{(1)}$  ;
  - ③ 从  $Exp(\lambda_1 - log(p^{(1)}))$  中模拟产生  $\alpha^{(1)}$  ;
  - ④ 从  $Exp(\lambda_2 - log(1 - p^{(1)}))$  中模拟产生  $\beta^{(1)}$  ;
  - ⑤ 完成  $\theta^{(0)} = (\alpha^{(0)}, \beta^{(0)}, p^{(0)})$  到  $\theta^{(1)} = (\alpha^{(1)}, \beta^{(1)}, p^{(1)})$  的模拟。重复上述过程②至④, 产生  $\theta^{(m)}$ .....。

----- end 20240601

## 第四节 马氏链随机模拟

- 
- ① 产生起始点  $\theta^{(0)} = (\alpha^{(0)}, \beta^{(0)}, p^{(0)})$ , 其中  $\alpha^{(0)} \sim Exp(\lambda_1)$ ,  
 $\beta^{(0)} \sim Exp(\lambda_2)$ ,  $p^{(0)} \sim Be(\alpha^{(0)}, \beta^{(0)})$  ;
  - ② 从  $Be(\alpha^{(0)} + \sum X_i, \beta^{(0)} + n - \sum X_i)$  中模拟产生  $p^{(1)}$ ;
  - ③ 从  $Exp(\lambda_1 - log(p^{(1)}))$  中模拟产生  $\alpha^{(1)}$ ;
  - ④ 从  $Exp(\lambda_2 - log(1 - p^{(1)}))$  中模拟产生  $\beta^{(1)}$ ;
  - ⑤ 完成  $\theta^{(0)} = (\alpha^{(0)}, \beta^{(0)}, p^{(0)})$  到  $\theta^{(1)} = (\alpha^{(1)}, \beta^{(1)}, p^{(1)})$  的模拟。重复上述过程②至④, 产生  $\theta^{(m)}$ .....。

## 第四节 马氏链随机模拟

例2. 某个MCMC算法中的某个步骤，需要从 $f(\theta) = C(\theta^2 + 2 + 4/(\theta^4 + 1))$  ( $\theta \in [0, 1]$ ) 中抽样，完成从 $\theta^{(m)}$ 到 $\theta^{(m+1)}$ 的更新， $C$ 是待定常数。如何完成？

解：不妨取转移函数 $q(\theta^{(m)}, \theta')$ 为 $U(0, 1)$ （或某个 $Be$ 分布），即独立于 $\theta^{(m)}$ 产生 $\theta^{(m+1)}$ 的候选 $\theta'$ ，则Hastings ratio  $r(\theta^{(m)}, \theta')$ 的计算为：

$$\begin{aligned} r(\theta^{(m)}, \theta') &= \frac{\pi(\theta')q(\theta', \theta^{(m)})}{\pi(\theta^{(m)})q(\theta^{(m)}, \theta')} = \frac{C(\theta'^2 + 2 + 4/(\theta'^4 + 1)) \cdot 1}{C(\theta^{(m)2} + 2 + 4/(\theta^{(m)4} + 1)) \cdot 1} \\ &= \frac{\theta'^2 + 2 + 4/(\theta'^4 + 1)}{\theta^{(m)2} + 2 + 4/(\theta^{(m)4} + 1)} \end{aligned}$$

当其 $\geq 1$ 时，以概率1令 $\theta^{(m+1)} = \theta'$ ；

当其 $< 1$ 时，以概率 $r(\theta^{(m)}, \theta')$ 令 $\theta^{(m+1)} = \theta'$ ，以概率 $1 - r(\theta^{(m)}, \theta')$ 令 $\theta^{(m+1)} = \theta^{(m)}$ 。

有时，部分参数以正概率不更新的情形，比Gibbs sampler有更快的收敛速度。

# 第八章 抽样调查概述

## 第一节 简介

- 统计学中重要、且很有实用价值的方向，研究如何方便、简捷、有效地得到有代表性的“好”样本。
- 常具有较大新闻价值、商业价值、社会价值等，也需要一定费用。
- “简单随机子样”可能很难、有时甚至不可能得到，例如如何抽取5000个代表所有北京人？
- 历史上，1936年，《文学摘要》发出一千多万问卷，预测兰登以57%比43%获胜，实际上罗斯福以62%比38%获胜，为何差距这么大？
  - ① 问卷选取有偏，偏重富人；
  - ② 回答有偏，仅1/4弱的人寄回问卷，一般多为其中中等收入者，即存在回答偏倚。

# 第一节 简介



- 大样本量可能无用，仅重复错误。
- 盖洛普仅用几千个样本，得到了显著改善的预测，但其预测罗斯福 56% 比例获胜，仍有 6% 偏差：获得全体选民的随机样本不容易。
- 面询抽样：常有主观偏差，找面容和善者。
- 入户调查：易抽到家庭主妇，退休人士。
- 比例抽样：比例未知或不准确。
- 流行病学调查：样本相对固定。
- 数据缺失：一些人对部分或全部问题不回答（MAR、MCAR、MN）。

# 第一节 简介



## 问卷设计的一个（经典）例子

对敏感问题的调查中，若直接询问，被询问者常不配合，如调查吸毒率 $r$ 。一个解决方法是，设是否吸毒与生日上、下半年相互独立，则概率分布如下表：

|    | 上半年出生       | 下半年出生       |
|----|-------------|-------------|
| 吸毒 | $r/2$       | $r/2$       |
| 不吸 | $(1 - r)/2$ | $(1 - r)/2$ |

对路人的问题是：你是否生日在下半年，且不吸毒？问题不敏感。回答是或否的概率分别为 $(1-r)/2$ 、 $(1+r)/2$ ，若数据分别为 $n_1$ 、 $n_2$ ，则由估计方程

$$\frac{n_1}{n_2} = \frac{(1 - r)/2}{(1 + r)/2}$$

可得估计量 $\hat{r} = (n_2 - n_1) / (n_2 + n_1)$ 。它是MLE。

## 第二节 单纯随机抽样

设总体为 $\{u_1, \dots, u_N\}$ （人群有限），其中相应指标值为 $\{Y_1, \dots, Y_N\}$ ，我们希望估计 $\bar{Y} = \frac{1}{N} \sum_{i=1}^N Y_i$ 。

完全随机的抽样法为：

- ① 从 $N$ 个单元中抽取一个，记为 $y_1$ ；
- ② 从其余 $N - 1$ 个单元中抽取一个，记为 $y_2$ ；

... ...

此方法称为单纯随机抽样，取得的 $n$ 个样本，称为单纯随机样本。

定理1. 设 $y_1, \dots, y_n$ 是从 $\{Y_1, \dots, Y_N\}$ 中得到的单纯随机样本，则 $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ 是 $\bar{Y}$ 的无偏估计，其均方误差为 $Var(\bar{y}) = \frac{1}{n} \left(1 - \frac{n}{N}\right) S^2$ ，其中 $S^2 = \frac{1}{N-1} \sum_{i=1}^N (Y_i - \bar{Y})^2$ 。

## 第二节 单纯随机抽样

证明：

记  $D_i = \begin{cases} 1 & \text{若第 } i \text{ 个单元进入样本,} \\ 0 & \text{否则} \end{cases}$ , 则

$$E(D_i) = P(D_i = 1) = \frac{1 \cdot C_{N-1}^{n-1}}{C_N^n} = \frac{n}{N}$$

$$E(D_i D_j) = P(D_i = 1, D_j = 1) = \frac{1 \cdot 1 \cdot C_{N-2}^{n-2}}{C_N^n} = \frac{n(n-1)}{N(N-1)} \quad (i \neq j)$$

故

$$E(\bar{y}) = E\left(\frac{1}{n} \sum_{i=1}^N D_i Y_i\right) = \frac{1}{n} \sum_{i=1}^N Y_i E(D_i) = \frac{1}{N} \sum_{i=1}^N Y_i = \bar{Y}$$

$$E(\bar{y}^2) = \frac{1}{n^2} E\left[\left(\sum_{i=1}^N D_i Y_i\right)^2\right] = \frac{1}{n^2} E\left(\sum_{i=1}^N D_i Y_i^2 + 2 \sum_{i < j} D_i D_j Y_i Y_j\right)$$

## 第二节 单纯随机抽样

$$\begin{aligned} &= \frac{1}{n^2} \sum_{i=1}^N Y_i^2 \frac{n}{N} + \frac{2}{n^2} \sum_{i < j} Y_i Y_j \frac{n(n-1)}{N(N-1)} \\ &= \frac{1}{nN} \sum_{i=1}^N Y_i^2 + \frac{2(n-1)}{nN(N-1)} \sum_{i < j} Y_i Y_j \end{aligned}$$

所以

$$\begin{aligned} Var(\bar{y}) &= E(\bar{y}^2) - (E\bar{y})^2 \\ &= \frac{1}{nN} \sum_{i=1}^N Y_i^2 + \frac{2(n-1)}{nN(N-1)} \sum_{i < j} Y_i Y_j - \frac{1}{N^2} \sum_{i=1}^N Y_i^2 - \frac{2}{N^2} \sum_{i < j} Y_i Y_j \quad (= (E\bar{y})^2) \\ &= \frac{N-n}{nN^2} \sum_{i=1}^N Y_i^2 - 2 \frac{N-n}{nN^2(N-1)} \sum_{i < j} Y_i Y_j \\ &= \frac{N-n}{nN^2} \sum_{i=1}^N Y_i^2 - \frac{N-n}{nN^2(N-1)} \left[ \sum_{i=1}^N Y_i^2 + 2 \sum_{i < j} Y_i Y_j \right] + \frac{N-n}{nN^2(N-1)} \sum_{i=1}^N Y_i^2 \\ &= \frac{1}{n} \left( 1 - \frac{n}{N} \right) \frac{1}{N-1} \left[ \sum_{i=1}^N Y_i^2 - \frac{1}{N} \left( \sum_{i=1}^N Y_i \right)^2 \right] = \frac{1}{n} \left( 1 - \frac{n}{N} \right) S^2 \end{aligned}$$

证毕。

## 第二节 单纯随机抽样

定理2.  $v(\bar{y}) = \frac{1}{n} \left(1 - \frac{n}{N}\right) s^2$  是  $Var(\bar{y})$  的无偏估计, 其中  $s^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$ 。

证明: 由定理1, 只需证  $E s^2 = S^2$ , 而

$$s^2 = \frac{1}{n-1} \left[ \sum_{i=1}^n y_i^2 - n\bar{y}^2 \right] = \frac{1}{n-1} \left[ \sum_{i=1}^N Y_i^2 D_i - n\bar{y}^2 \right]$$
$$E(s^2) = \frac{1}{n-1} \left[ \sum_{i=1}^N Y_i^2 E(D_i) - nE(\bar{y}^2) \right]$$

而

$$E(\bar{y}^2) = var(\bar{y}) + E(\bar{y})^2 = \frac{1}{n} \left(1 - \frac{n}{N}\right) S^2 + \left(\frac{1}{N} \sum_{i=1}^N Y_i\right)^2$$

所以

$$E(s^2)$$
$$= \frac{1}{n-1} \left[ \frac{n}{N} \sum_{i=1}^N Y_i^2 - n \left( \frac{1}{n} \left(1 - \frac{n}{N}\right) S^2 + \left(\frac{1}{N} \sum_{i=1}^N Y_i\right)^2 \right) \right]$$

## 第二节 单纯随机抽样



$$= \frac{1}{n-1} \left[ \frac{n}{N} (N-1) S^2 - \left(1 - \frac{n}{N}\right) S^2 \right] = S^2$$

证毕。

由上面两个定理， $\bar{y}$ 是 $\bar{Y}$ 一个很好的点估计，其方差可以用 $v(\bar{y})$ 估计。

- 若想估计某年北京人均收入，只需抽取 $n$ 个单纯随机样本即可（如果能做到），利用定理1，求平均。
- 若想得知上述估计的精度，利用定理2即可。
- 更有信息量的描述：给出分位点。
- 对于收入，一般地，中位数<人均收入。

# 关于期末考试

- 
- 考试时间：2024年6月13日，周四，下午2: 00-4: 00
  - 考试地点：二教203
  - 考试要求：闭卷；严禁作弊；不得使用计算器等任何电子设备；手机按学校要求放好。
  - 分数分布：多数为基础题，约20%有一定难度题，约20%稍难题。
  - 答疑：6月12日下午2: 00-4: 00，6月13日上午9: 00-11: 00，335/智华楼。
  - 期中考试及平时作业成绩：有特殊情况的提前向助教说明。
  - 关于答卷：你有权利，但希望尊重别人；判分标准的解释权归改卷人。

# 总复习



## 第二章

似然函数，最大似然估计，矩估计，相合性，无偏估计，均方误差，一致最小方差无偏估计，充分统计量，完全统计量，指数分布族，C-R不等式，置信区间（置信上限、置信下限）， $\chi^2$ 分布， $t$ 分布，自由度，枢轴量方法，统计量方法\*，经验分布函数，直方图法，核估计法\*。

## 第三章

零假设，否定域，随机化检验法\*，第I类错误，第II类错误，功效函数，UMP检验，无偏检验，UMPU检验，N-P引理，似然比检验法，单参数指数族的四种典型问题（四个定理），假设检验与置信区间的对应关系，广义似然比检验法，检验法的相合性\*，一些常见（正态）问题的检验法， $F$ 分布及其性质，临界值与 $p$ 值，拟合优度检验\*（ $\chi^2$ 检验、独立性检验、Kolmogorov检验）。

# 总复习



## 第四章

自（协）变量，因（响应）变量，一元线性回归，最小二乘估计，残差，平方和分解，相关系数，预测，控制；线性模型，投影方法，线性可估性，高斯-马尔科夫定理，带约束的线性模型的参数估计，线性模型的假设检验（定理4.1、定理4.3等），多元回归模型的估计、检验、预测等，回归方程的解释，自变量选择\*，线性性检验与残差分析\*，Logistic模型\*，Probit模型\*。

## 第五章 试验设计与方差分析

单因素、两因素全面试验的方差分析，可加模型，重复试验，平方和（方差）分解公式及其背景和统计意义，方差分析表，正交设计\*。

# 总复习



## 第六章 序贯分析初步

随机游动\*，停止时间\*，序贯判决法则\*，序贯概率比检验\*。

## 第七章 统计决策与贝叶斯统计大意

决策论，损失函数，可容许性，minimax准则，效用函数\*，主观概率，先验分布，后验分布，贝叶斯置信区间，预测分布\*，贝叶斯决策，共轭分布族，马尔科夫链随机模拟\*。

## 第八章 抽样调查概述

抽样调查的意义\*，单纯随机抽样\*。



感谢所有同学的参与！

感谢助教王啸辰、杨云帆的帮助！