

最速下降法和共轭梯度法

教师: 胡俊

北京大学数学科学学院

October 24, 2019

目录

- ① 最速下降法
- ② 共轭梯度法
- ③ 实用共轭梯度法
- ④ 预优共轭梯度法
- ⑤ 广义极小剩余法

目录

- 1 最速下降法
- 2 共轭梯度法
- 3 实用共轭梯度法
- 4 预优共轭梯度法
- 5 广义极小剩余法

最速下降法

考虑线性方程组

$$Ax = b \quad (1.1)$$

的求解问题, 其中矩阵 A 是对称正定的. 定义二次泛函

$$\varphi(x) = x^T Ax - 2b^T x. \quad (1.2)$$

定理: 设 A 是对称正定的, 求方程组 $Ax = b$ 的解等价于求解二次泛函 $\varphi(x)$ 的极小值点.

证明: 直接计算可得

$$\frac{\partial \varphi}{\partial x_i} = 2(a_{i1}x_1 + \cdots + a_{in}x_n) - 2b_i, i = 1, \cdots, n.$$

令 $r = b - Ax$, 则有

$$\text{grad}\varphi(x) = 2(Ax - b) = -2r.$$

若 $\varphi(x)$ 在 x_* 达到极小, 则必有 $\text{grad}\varphi(x_*) = 0$, 从而有 $Ax_* = b$.

反之, 若 x_* 是方程的解, 则对任意向量 y , 有

$$\begin{aligned}\varphi(x_* + y) &= (x_* + y)^T A(x_* + y) - 2b^T(x_* + y) \\ &= x_*^T A x_* - 2b^T x_* + y^T A y = \varphi(x_*) + y^T A y.\end{aligned}$$

当 A 正定时, 有 $y^T A y > 0$, 因此

$$\varphi(x_* + y) \geq \varphi(x_*)$$

即 x_* 使得 $\varphi(x)$ 到极小. 证毕.

类盲人下山法

先任意给定一个初始向量 x_0 ，确定一个下山的方向 p_0 ，沿着经过点 x_0 而方向为 p_0 的直线 $x = x_0 + \alpha p_0$ 找一个点

$$x_1 = x_0 + \alpha_0 p_0,$$

使得对所有实数 α , 有

$$\varphi(x_0 + \alpha_0 p_0) \leq \varphi(x_0 + \alpha p_0).$$

也就是说，在这条直线上， x_1 使 $\varphi(x)$ 到达极小. 然后从 x_1 出发，再确定一个下山的方向 p_1 ，沿着直线

$$x = x_1 + \alpha p_1$$

再跨一步，即找到 α_1 使得 $\varphi(x)$ 在 $x_2 = x_1 + \alpha_1 p_1$ 达到极小：

$$\varphi(x_1 + \alpha_1 p_1) \leq \varphi(x_1 + \alpha p_1).$$

如此下去，得到一个序列：

$$(p_0, \alpha_0), (p_1, \alpha_1), (p_2, \alpha_2), \cdots, .$$

称 p_k 为搜索方向， α_k 为步长. 一般地，先在 x_k 点招一个下山方向 p_k ，再在直线 $x = x_k + \alpha p_k$ 上确定步长 α_k 使得

$$\varphi(x_k + \alpha_k p_k) \leq \varphi(x_k + \alpha p_k).$$

最后求出 $x_{k+1} = x_k + \alpha_k p_k$.

步长的确定

令

$$\begin{aligned} f(\alpha) &= \varphi(x_k + \alpha p_k) \\ &= (x_k + \alpha p_k)^T A(x_k + \alpha p_k) - 2b^T(x_k + \alpha p_k) \\ &= \alpha^2 p_k^T A p_k - 2\alpha r_k^T p_k + \varphi(x_k), \end{aligned}$$

其中 $r_k = b - Ax_k$.

$$f'(\alpha) = 2\alpha p_k^T A p_k - 2r_k^T p_k = 0.$$

因此

$$\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}, x_{k+1} = x_k + \alpha_k p_k.$$

注：由 $\alpha_k p_k^T A p_k - r_k^T p_k = 0$,

和 $x_{k+1} = x_k + \alpha_k p_k$ 即 $r_{k+1} = r_k - \alpha_k A p_k$, 可得 $p_k^T r_{k+1} = 0$.

下山方向的确定

由于

$$\begin{aligned}\varphi(x_{k+1}) - \varphi(x_k) &= \alpha_k^2 p_k^T A p_k - 2\alpha_k r_k^T p_k \\ &= -\frac{(r_k^T p_k)^2}{p_k^T A p_k}.\end{aligned}$$

因此, 只要 $r_k^T p_k \neq 0$, 就有 $\varphi(x_{k+1}) < \varphi(x_k)$.

因为梯度方向是增加最快的方向, 因此负梯度方向是下降最快的方向. 因而, 取 $p_k = r_k$.

算法及收敛性

算法(解对称正定方程组: 最速下降法)

x_0 =初值

$r_0 = b - Ax_0$; $k=0$

While $r_k \neq 0$

$k = k + 1$

$\alpha_{k-1} = r_{k-1}^T r_{k-1} / r_{k-1}^T A r_{k-1}$

$x_k = x_{k-1} + \alpha_{k-1} r_{k-1}$

$r_k = b - Ax_k$

End

最速下降方法的收敛性

引理： 设 A 的特征值为 $0 < \lambda_1 \leq \dots \leq \lambda_n$, $P(t)$ 是一个 t 的多项式, 则

$$\|P(A)x\|_A \leq \max_{1 \leq i \leq n} |P(\lambda_i)| \|x\|_A, \forall x \in \mathbb{R}^n.$$

证明： 设 y_1, y_2, \dots, y_n 是 A 的对应于 $\lambda_1, \lambda_2, \dots, \lambda_n$ 的特征向量所构成的 \mathbb{R}^n 一组标准正交基, 则对任意 $x \in \mathbb{R}^n$, 有 $x = \sum_{i=1}^n \beta_i y_i$, 从而有

$$\begin{aligned} x^T P(A) A P(A) x &= \left(\sum_{i=1}^n \beta_i P(\lambda_i) y_i \right)^T A \left(\sum_{i=1}^n \beta_i P(\lambda_i) y_i \right) \\ &= \sum_{i=1}^n \lambda_i \beta_i^2 P^2(\lambda_i) \leq \max_{1 \leq i \leq n} P^2(\lambda_i) \sum_{i=1}^n \lambda_i \beta_i^2 = \max_{1 \leq i \leq n} P^2(\lambda_i) x^T A x. \end{aligned}$$

定理： 设 A 的特征值为 $0 < \lambda_1 \leq \dots \leq \lambda_n$, 则上述算法产生的序列 $\{x_k\}$ 满足

$$\|x_k - x_*\|_A \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^k \|x_0 - x_*\|_A.$$

证明：

$$\varphi(x_k) \leq \varphi(x_{k-1} + \alpha p_{k-1}), \forall \alpha \in \mathbb{R}.$$

并注意到

$$\varphi(x) + x_*^T A x_* = (x - x_*)^T A (x - x_*),$$

有

$$\begin{aligned} & (x_k - x_*)^T A (x_k - x_*) \\ & \leq (x_{k-1} + \alpha r_{k-1} - x_*)^T A (x_{k-1} + \alpha r_{k-1} - x_*) \\ & = [(I - \alpha A)(x_{k-1} - x_*)]^T A [(I - \alpha A)(x_{k-1} - x_*)] \end{aligned}$$

对任意 $\alpha \in \mathbb{R}$ 成立.

记 $P_\alpha(t) = 1 - \alpha t$, 由上述引理, 有

$$\|x_k - x_*\|_A \leq \min_{\alpha} \max_{1 \leq i \leq n} |P_\alpha(\lambda_i)| \|x_{k-1} - x_*\|_A.$$

因为

$$\max_{1 \leq i \leq n} |P_\alpha(\lambda_i)| = \max(|1 - \alpha\lambda_1|, |1 - \alpha\lambda_n|)$$

显然, 当

$$1 - \alpha\lambda_1 = \alpha\lambda_n - 1$$

时, 上述最大值取得最小, 此时

$$\alpha = \frac{2}{\lambda_1 + \lambda_n}.$$

这样

$$\|x_k - x_*\|_A \leq \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \|x_{k-1} - x_*\|_A.$$

证毕.

目录

- ① 最速下降法
- ② 共轭梯度法
- ③ 实用共轭梯度法
- ④ 预优共轭梯度法
- ⑤ 广义极小剩余法

共轭梯度法

对最速下降法做一简单的分析就会发现, 负梯度方向虽从局部来看是最佳的下山方向, 但从整体来看并非最佳. 这就促使人们去寻求更好的下山方向. 当然, 我们自然希望每步确定新的下山方向所付出的代价不要太大. **共轭梯度法**就是根据这一思想设计的, 其具体计算过程如下:

给定初始向量 x_0 , 第一步仍选负梯度方向为下山方向, 即 $p_0 = r_0$, 于是有

$$\alpha_0 = \frac{r_0^T r_0}{p_0^T A p_0}, \quad x_1 = x_0 + \alpha_0 p_0, \quad r_1 = b - A x_1.$$

对以后各步, 例如, 第 $k+1$ ($k \geq 1$)步, 下山方向就不再取 r_k , 而是在过点 x_k 由向量 r_k 和 p_{k-1} 所张成的二维平面

$$\pi_2 = \{x = x_k + \xi r_k + \eta p_{k-1} : \xi, \eta \in \mathbf{R}\}$$

内找出使函数 φ 下降最快的方向作为新的下山方向 p_k .

考虑 φ 在 π_2 上的限制:

$$\begin{aligned}\psi(\xi, \eta) &= \varphi(x_k + \xi r_k + \eta p_{k-1}) \\ &= (x_k + \xi r_k + \eta p_{k-1})^T A (x_k + \xi r_k + \eta p_{k-1}) \\ &\quad - 2b^T (x_k + \xi r_k + \eta p_{k-1}).\end{aligned}$$

直接计算可得

$$\begin{aligned}\frac{\partial \psi}{\partial \xi} &= 2(\xi r_k^T A r_k + \eta r_k^T A p_{k-1} - r_k^T r_k), \\ \frac{\partial \psi}{\partial \eta} &= 2(\xi r_k^T A p_{k-1} + \eta p_{k-1}^T A p_{k-1}),\end{aligned}$$

其中最后一式用到了 $r_k^T p_{k-1} = 0$, 这可由 r_k 的定义直接验证. 令

$$\frac{\partial \psi}{\partial \xi} = \frac{\partial \psi}{\partial \eta} = 0,$$

即知 φ 在 π_2 内有唯一的极小值点

$$\tilde{x} = x_k + \xi_0 r_k + \eta_0 p_{k-1},$$

其中 ξ_0 和 η_0 满足

$$\begin{cases} \xi_0 r_k^T A r_k + \eta_0 r_k^T A p_{k-1} = r_k^T r_k, \\ \xi_0 r_k^T A p_{k-1} + \eta_0 p_{k-1}^T A p_{k-1} = 0. \end{cases} \quad (5.2.1)$$

注意, 上式蕴含着 $r_k \neq 0$ 必有 $\xi_0 \neq 0$, 因此我们可取

$$p_k = \frac{1}{\xi_0}(\tilde{x} - x_k) = r_k + \frac{\eta_0}{\xi_0} p_{k-1}$$

作为新的下山方向. 显然这是在平面 π_2 内可得到的最佳下山方向. 令 $\beta_{k-1} = \frac{\eta_0}{\xi_0}$, 则由(5.2.1)式的第二个方程得

$$\beta_{k-1} = -\frac{r_k^T A p_{k-1}}{p_{k-1}^T A p_{k-1}}.$$

注意这样确定的 p_k 满足 $p_k^T A p_{k-1} = 0$, 即所谓的 p_k 与 p_{k-1} 是相互共轭的.

p_k 确定以后, α_k 的确定仍用前面的公式, 然后计算 $x_{k+1} = x_k + \alpha_k p_k$. 总结上面的讨论, 可得如下的计算公式:

$$\begin{aligned}\alpha_k &= \frac{r_k^T p_k}{p_k^T A p_k}, & x_{k+1} &= x_k + \alpha_k p_k \\ r_{k+1} &= b - A x_{k+1}, & & \\ \beta_k &= -\frac{r_{k+1}^T A p_k}{p_k^T A p_k}, & p_{k+1} &= r_{k+1} + \beta_k p_k.\end{aligned}\tag{5.2.2}$$

在实际计算中, 常将上述公式进一步简化, 从而得到一个形式上更为简单而且对称的计算公式. 首先来简化 r_{k+1} 的计算公式:

$$\begin{aligned}r_{k+1} &= b - A x_{k+1} = b - A(x_k + \alpha_k p_k) \\ &= r_k - \alpha_k A p_k.\end{aligned}\tag{5.2.3}$$

因为 $A p_k$ 在计算 α_k 时已经求出, 所以计算 r_{k+1} 时可以不必将 x_{k+1} 代入方程去计算, 而是从递推关系(5.2.3)得到.

再来简化 α_k 和 β_k 的计算公式. 我们需要用到下面的关系式:

$$r_k^T r_{k+1} = r_k^T p_{k-1} = r_{k+1}^T p_k = 0, \quad k = 1, 2, \dots. \quad (5.2.4)$$

这些关系式的证明包含在定理5.2.1的证明中. 从(5.2.4)式和(5.2.3)式可导出

$$\begin{aligned} r_{k+1}^T A p_k &= \frac{1}{\alpha_k} r_{k+1}^T (r_k - r_{k+1}) = -\frac{1}{\alpha_k} r_{k+1}^T r_{k+1}, \\ p_k^T A p_k &= \frac{1}{\alpha_k} p_k^T (r_k - r_{k+1}) = \frac{1}{\alpha_k} p_k^T r_k \\ &= \frac{1}{\alpha_k} r_k^T (r_k + \beta_{k-1} p_{k-1}) = \frac{1}{\alpha_k} r_k^T r_k. \end{aligned} \quad (5.2.5)$$

由此可得

$$\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}, \quad \beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}. \quad (5.2.6)$$

综合上面的讨论, 可得下面的算法:

算法5.2.1(解对称正定方程组: 共轭梯度法)

$x_0 =$ 初值

$r_0 = b - Ax_0; k = 0$

while $r_k \neq 0$

$k = k + 1$

if $k = 1$

$p_0 = r_0$

else

$\beta_{k-2} = r_{k-1}^T r_{k-1} / r_{k-2}^T r_{k-2}$

$p_{k-1} = r_{k-1} + \beta_{k-2} p_{k-2}$

end

$\alpha_{k-1} = r_{k-1}^T r_{k-1} / p_{k-1}^T A p_{k-1}$

$x_k = x_{k-1} + \alpha_{k-1} p_{k-1}$

$r_k = r_{k-1} - \alpha_{k-1} A p_{k-1}$

end

$x = x_k$

注意, 该算法每迭代一次仅需使用系数矩阵 A 做一次矩阵-向量运算.

共轭梯度法的基本性质

定理 (5.2.1)

由共轭梯度法得到的向量组 $\{r_i\}$ 和 $\{p_i\}$ 具有下面的性质:

- (1) $p_i^T r_j = 0, 0 \leq i < j \leq k;$
- (2) $r_i^T r_j = 0, i \neq j, 0 \leq i, j \leq k;$
- (3) $p_i^T A p_j = 0, i \neq j, 0 \leq i, j \leq k;$
- (4) $\text{span}\{r_0, \dots, r_k\} = \text{span}\{p_0, \dots, p_k\} = \mathcal{K}(A, r_0, k+1),$ 其中

$$\mathcal{K}(A, r_0, k+1) = \text{span}\{r_0, A r_0, \dots, A^k r_0\}, \quad (5.2.6b)$$

通常称之为**Krylov**子空间.

证明 用数学归纳法. 当 $k = 1$ 时, 因为

$$\begin{aligned} p_0 &= r_0, \quad r_1 = r_0 - \alpha_0 A p_0, \quad p_1 = r_1 + \beta_0 p_0, \\ r_1^T r_0 &= r_0^T (r_0 - \alpha_0 A r_0) = r_0^T r_0 - \alpha_0 r_0^T A r_0 = 0, \\ p_1^T A p_0 &= (r_1 + \beta_0 r_0)^T A r_0 = r_1^T A r_0 - \frac{r_1^T A r_0}{r_0^T A r_0} r_0^T A r_0 = 0, \end{aligned}$$

所以定理的结论成立. 现在假设定理得结论对 k 成立, 我们来证明其对 $k + 1$ 也成立.

(1) 利用等式 $r_{k+1} = r_k - \alpha_k A p_k$ 及归纳法假设, 有

$$p_i^T r_{k+1} = p_i^T r_k - \alpha_k p_i^T A p_k = 0, \quad 0 \leq i \leq k - 1.$$

又由于

$$p_k^T r_{k+1} = p_k^T r_k - \frac{p_k^T r_k}{p_k^T A p_k} p_k^T A p_k = 0,$$

故定理的结论(1)对 $k + 1$ 亦成立.

(2)利用归纳法假设有

$$\text{span}\{r_0, \dots, r_k\} = \text{span}\{p_0, \dots, p_k\}$$

而由(1)所证知, r_{k+1} 与上述子空间正交, 从而定理的结论(2)对 $k+1$ 也成立.

(3)利用等式

$$p_{k+1} = r_{k+1} + \beta_k p_k \text{ 和 } r_{i+1} = r_i - \alpha_i A p_i,$$

并利用归纳法假设和(2)所证的结论, 就有

$$p_i^T A p_{k+1} = \frac{1}{\alpha_i} r_{k+1}^T (r_i - r_{i+1}) + \beta_k p_i^T A p_k = 0$$

对 $i = 0, 1, \dots, k-1$ 成立, 而由 β_k 的定义得

$$\begin{aligned} p_{k+1}^T A p_k &= (r_{k+1} + \beta_k p_k)^T A p_k \\ &= r_{k+1}^T A p_k - \frac{r_{k+1}^T A p_k}{p_k^T A p_k} p_k^T A p_k = 0. \end{aligned}$$

这样, 定理的结论(3)对 $k+1$ 也成立.

(4)由归纳法假设知

$$r_k, p_k \in \mathcal{K}(A, r_0, k+1) = \text{span}\{r_0, Ar_0, \dots, A^k r_0\},$$

于是

$$r_{k+1} = r_k - \alpha_k A p_k \in \mathcal{K}(A, r_0, k+2) = \text{span}\{r_0, Ar_0, \dots, A^{k+1} r_0\},$$

$$p_{k+1} = r_{k+1} + \beta_k p_k \in \mathcal{K}(A, r_0, k+2) = \text{span}\{r_0, Ar_0, \dots, A^{k+1} r_0\}.$$

再注意到(2)和(3)所证的结论表明, 向量组 r_0, \dots, r_{k+1} 和 p_0, \dots, p_{k+1} 都是线性无关的, 因此定理的结论(4)对 $k+1$ 同样成立.

综上所述, 由归纳法原理知定理得证.

定理5.2.1表明, 向量组 r_0, \dots, r_k 和 p_0, \dots, p_k 分别是Krylov子空间 $\mathcal{K}(A, r_0, k+1)$ 的正交基和共轭正交基. 由此可知, 利用共轭梯度法最多 n 步便可得到方程组的解 x_* . 因此, 理论上来讲, 共轭梯度法是直接法.

定理 (5.2.2)

用共轭梯度法计算得到的近似解 x_k 满足

$$\varphi(x_k) = \min\{\varphi(x) : x \in x_0 + \mathcal{K}(A, r_0, k)\} \quad (5.2.7)$$

或

$$\|x_k - x_*\|_A = \min\{\|x - x_*\|_A : x \in x_0 + \mathcal{K}(A, r_0, k)\}, \quad (5.2.8)$$

其中 $\|x\|_A = \sqrt{x^T A x}$, x_* 是方程组 $Ax = b$ 的解, $\mathcal{K}(A, r_0, k)$ 是(5.2.6b)式所定义的Krylov子空间.

证明 利用(5.1.4)式立即知道(5.2.7)式和(5.2.8)式是等价的, 因此我们下面只证明(5.2.8)式成立.

假设共轭梯度法计算到 ℓ 步出现 $r_\ell = 0$, 那么有

$$\begin{aligned} x_* &= x_\ell = x_{\ell-1} + \alpha_{\ell-1}p_{\ell-1} \\ &= x_{\ell-2} + \alpha_{\ell-2}p_{\ell-2} + \alpha_{\ell-1}p_{\ell-1} \\ &= \cdots \\ &= x_0 + \alpha_0p_0 + \alpha_1p_1 + \cdots, \alpha_{\ell-1}p_{\ell-1}. \end{aligned}$$

此外, 对计算过程中的任一步 $k < \ell$, 有

$$x_k = x_0 + \alpha_0p_0 + \alpha_1p_1 + \cdots + \alpha_{k-1}p_{k-1} \in x_0 + \mathcal{K}(A, r_0, k).$$

设 x 是属于 $x_0 + \mathcal{K}(A, r_0, k)$ 的任一向量, 则由定理5.2.1 的(4)知, x 可以表示为

$$x = x_0 + \gamma_0p_0 + \gamma_1p_1 + \cdots + \gamma_{k-1}p_{k-1}.$$

于是

$$\begin{aligned} x_* - x = & (\alpha_0 - \gamma_0)p_0 + \cdots + (\alpha_{k-1} - \gamma_{k-1})p_{k-1} \\ & + \alpha_k p_k + \cdots + \alpha_{\ell-1} p_{\ell-1}, \end{aligned}$$

而 $x_* - x_k = \alpha_k p_k + \cdots + \alpha_{\ell-1} p_{\ell-1}$, 再利用定理5.2.1的(3)就可以推出

$$\begin{aligned} \|x_* - x\|_A^2 &= \|(\alpha_0 - \gamma_0)p_0 + \cdots + (\alpha_{k-1} - \gamma_{k-1})p_{k-1}\|_A^2 \\ &\quad + \|\alpha_k p_k + \cdots + \alpha_{\ell-1} p_{\ell-1}\|_A^2 \\ &\geq \|\alpha_k p_k + \cdots + \alpha_{\ell-1} p_{\ell-1}\|_A^2 = \|x_* - x_k\|_A^2, \end{aligned}$$

从而定理得证.

目录

- 1 最速下降法
- 2 共轭梯度法
- 3 实用共轭梯度法
- 4 预优共轭梯度法
- 5 广义极小剩余法

实用共轭梯度法

算法(解对称正定方程组: 实用共轭梯度法)

x =初值

$r = b - Ax$; $\rho = r^T r$; $k=0$

While ($\sqrt{\rho} > \epsilon \|b\|_2$) and ($k < k_{max}$)

$k = k + 1$

if $k = 1$

$p = r$

else

$\beta = \rho / \tilde{\rho}$; $p = r + \beta p$

end

$w = Ap$; $\alpha = \rho / p^T w$; $x = x + \alpha p$

$r = r - \alpha w$; $\tilde{\rho} = \rho$; $\rho = r^T r$

end

实用共轭梯度法的收敛性分析

定理 (5.3.1)

如果 $A = I + B$ ，而且 $\text{rank}(B) = k$ ，则共轭梯度法至多迭代 $k + 1$ 步即得到方程的精确解。

证明： 注意到 $\text{rank}(B) = k$ 蕴涵着子空间

$$\text{span}\{r_0, Ar_0, \dots, A^k r_0\} = \text{span}\{r_0, Br_0, \dots, B^k r_0\}$$

的维数不会超过 $k + 1$. 证毕

定理 (5.3.2)

用共轭梯度法求得的 x_k 有如下的误差估计:

$$\|x_k - x_*\|_A \leq 2 \left(\frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k \|x_0 - x_*\|_A$$

其中 $\kappa_2 = \kappa_2(A) = \|A\|_2 \|A^{-1}\|_2$.

证明: 对任意 $x \in x_0 + \mathcal{K}(A, r_0, k)$, 有

$$\begin{aligned} x_* - x &= x_* - x_0 + a_{k1}r_0 + a_{k2}Ar_0 + \cdots + a_{kk}A^{k-1}r_0 \\ &= A^{-1}(r_0 + a_{k1}Ar_0 + a_{k2}A^2r_0 + \cdots + a_{kk}A^k r_0) \\ &= A^{-1}P_k(A)r_0, \end{aligned}$$

其中 $P_k(\lambda) = 1 + \sum_{j=1}^k a_{kj}\lambda^j$.

令 \mathcal{P}_k 为所有满足 $P_k(0) = 1$ 且次数不超过 k 的实系数多项式的全体. 这样

$$\begin{aligned}\|x_* - x_k\|_A &= \min\{\|x - x_*\|_A : x \in x_0 + \mathcal{K}(A, r_0, k)\} \\ &= \min_{P_k \in \mathcal{P}_k} \|A^{-1}P_k(A)r_0\|_A = \min_{P_k \in \mathcal{P}_k} \|P_k(A)A^{-1}r_0\|_A \\ &\leq \min_{P_k \in \mathcal{P}_k} \max_{1 \leq i \leq n} |P_k(\lambda_i)| \|A^{-1}r_0\|_A \\ &\leq \min_{P_k \in \mathcal{P}_k} \max_{a \leq \lambda \leq b} |P_k(\lambda)| \|x_0 - x_*\|_A,\end{aligned}$$

其中 $0 < a = \lambda_1 \leq \cdots \leq \lambda_n = b$ 是 A 的特征值. 由著名的Chebyshev多项式逼近定理知, 最优化问题

$$\min_{P_k \in \mathcal{P}_k} \max_{a \leq \lambda \leq b} |P_k(\lambda)|$$

有唯一的解

$$\tilde{P}_k(\lambda) = \frac{T_k\left(\frac{b+a-2\lambda}{b-a}\right)}{T_k\left(\frac{b+a}{b-a}\right)},$$

其中 $T_k(z)$ 是 k 次Chebyshev多项式. 由Chebyshev多项式的性质知

$$\max_{a \leq \lambda \leq b} |\tilde{P}_k(\lambda)| = \frac{1}{T_k(\frac{b+a}{b-a})} \leq 2 \left(\frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k.$$

于是, 我们有

$$\|x_k - x_*\|_A \leq 2 \left(\frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k \|x_0 - x_*\|_A.$$

因此, 定理得证.

$$T_k\left(\frac{b+a}{b-a}\right) = 2^{k-1} \frac{1}{2^k} \left\{ (x + \sqrt{x^2 - 1})^k + (x - \sqrt{x^2 - 1})^k \right\}$$

$$\left(\text{其中 } x = \frac{b+a}{b-a} \right)$$

$$= \frac{1}{2} \left\{ \left(\frac{(b+a) + \sqrt{(b+a)^2 - (b-a)^2}}{b-a} \right)^k + \left(\frac{(b+a) - \sqrt{(b+a)^2 - (b-a)^2}}{b-a} \right)^k \right\}$$

$$= \frac{1}{2} \left\{ \left(\frac{(b+a) + 2\sqrt{ab}}{b-a} \right)^k + \left(\frac{(b+a) - 2\sqrt{ab}}{b-a} \right)^k \right\}$$

因为,

$$b + a + 2\sqrt{ab} = (\sqrt{b} + \sqrt{a})^2, b + a - 2\sqrt{ab} = (\sqrt{b} - \sqrt{a})^2,$$

所以

$$T_k\left(\frac{b+a}{b-a}\right) = \frac{1 + \sigma^{2k}}{2\sigma^k}$$

其中 $\sigma = (\sqrt{b} - \sqrt{a})/(\sqrt{b} + \sqrt{a})$. 注意到

$$\frac{\sigma^k}{1 + \sigma^{2k}} \leq \left(\frac{\sqrt{b} - \sqrt{a}}{\sqrt{b} + \sqrt{a}} \right)^k$$

目录

- ① 最速下降法
- ② 共轭梯度法
- ③ 实用共轭梯度法
- ④ 预优共轭梯度法
- ⑤ 广义极小剩余法

先将方程组转化为

$$\tilde{A}\tilde{x} = \tilde{b},$$

其中 $\tilde{A} = C^{-1}AC^{-1}$, $\tilde{x} = Cx$, $\tilde{b} = C^{-1}b$, 这里要求 C 是对称正定的, 目的是通过 C 的选取, 使 \tilde{A} 具有良好性质.

$$\begin{aligned}\alpha_k &= \frac{\tilde{r}_k^T \tilde{r}_k}{\tilde{p}_k^T \tilde{A} \tilde{p}_k}, & \tilde{x}_{k+1} &= \tilde{x}_k + \alpha_k \tilde{p}_k \\ & & \tilde{r}_{k+1} &= \tilde{r}_k - \alpha_k \tilde{A} \tilde{p}_k, \\ \beta_k &= \frac{\tilde{r}_{k+1}^T \tilde{r}_{k+1}}{\tilde{r}_k^T \tilde{r}_k}, & \tilde{p}_{k+1} &= \tilde{r}_{k+1} + \beta_k \tilde{p}_k.\end{aligned}\tag{5.4.2}$$

$$\tilde{x}_k = Cx_k, \tilde{r}_k = C^{-1}r_k, \tilde{p}_k = Cp_k.$$

记 $M = C^2$

$$\begin{aligned}
 w_k &= Ap_k & \alpha_k &= \rho_k / (p_k^T w_k) \\
 x_{k+1} &= x_k + \alpha_k p_k & r_{k+1} &= r_k - \alpha_k w_k \\
 z_{k+1} &= M^{-1} r_{k+1} & \rho_{k+1} &= r_{k+1}^T z_{k+1} \\
 \beta_k &= \rho_{k+1} / \rho_k & p_{k+1} &= z_{k+1} + \beta_k p_k.
 \end{aligned}$$

其中 x_0 是任意给定的初始向量, $r_0 = b - Ax_0$, $z_0 = M^{-1}r_0$,
 $\rho_0 = r_0^T z_0$, $p_0 = z_0$.

算法

(解对称正定方程组: 预优共轭梯度法)

x =初值

$r = b - Ax$; $k=0$

While ($\sqrt{r^T r} > \epsilon \|b\|_2$) and ($k < k_{max}$)

 求解 $Mz = r$ 得 z

$k = k + 1$

if $k = 1$

$p = z$; $\rho = r^T z$

else

$\tilde{\rho} = \rho$; $\rho = r^T z$

$\beta = \rho / \tilde{\rho}$; $p = z + \beta p$

end

$w = Ap$; $\alpha = \rho / p^T w$;

$x = x + \alpha p$; $r = r - \alpha w$

end

这一算法也称为预条件共轭梯度法, 简称PCG, 其中的矩阵 M 称做预优矩阵. 利用共轭梯度法的性质容易导出预优共轭梯度法如下性质:

- ① 残量 r_k 是相互 M^{-1} 正交的, 即 $r_i^T M^{-1} r_j = 0, i \neq j$;
- ② 方向向量 p_k 是相互 A 正交的, 即 $p_i^T A p_j = 0, i \neq j$;
- ③ 近似解向量 x_k 满足

$$\|x_k - x_*\|_A \leq 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|x_0 - x_*\|_A,$$

其中 $\kappa = \lambda_n / \lambda_1$, λ_n 和 λ_1 是 $M^{-1}A$ 的最大和最小特征值.

目录

- 1 最速下降法
- 2 共轭梯度法
- 3 实用共轭梯度法
- 4 预优共轭梯度法
- 5 广义极小剩余法

广义极小剩余法

给定初始值 x_0 , 残量为 $r_0 = b - Ax_0$. 定义Krylov子空间

$$\kappa(A, r_0, k) = \text{span}\{r_0, Ar_0, \dots, A^{k-1}r_0\}.$$

在它上求解一个向量 \tilde{x}_k 使得剩余向量 $r_k = b - A(\tilde{x}_k + x_0)$ 满足

$$\|r_k\|_2 = \|b - A(\tilde{x}_k + x_0)\|_2 = \min = \|r_0 - A\tilde{x}_k\|_2$$

设

$$\begin{aligned}\kappa(A, r_0, m) &= \text{span}\{r_0, Ar_0, \dots, A^{m-1}r_0\} = \text{span}\{v_1, v_2, \dots, v_m\}, \\ m &= 1, 2, \dots, k+1,\end{aligned}$$

则有

$$\begin{aligned}Av_m &\in \kappa(A, r_0, m+1) = \text{span}\{r_0, Ar_0, \dots, A^{m-1}r_0, A^m r_0\} \\ &= \text{span}\{v_1, v_2, \dots, v_m, v_{m+1}\}.\end{aligned}$$

$$Av_m = h_{1m}v_1 + h_{2m}v_2 + \cdots + h_{mm}v_m + h_{m+1,m}v_{m+1}.$$

令

$$V_m = [v_1, v_2, \cdots, v_m]$$

$$H_m = \begin{bmatrix} h_{11} & h_{12} & \cdots & h_{1m} \\ h_{21} & h_{22} & \cdots & h_{2m} \\ & h_{32} & \ddots & \vdots \\ & & \ddots & h_{mm} \\ & & & h_{m+1,m} \end{bmatrix}$$

则有

$$AV_k = V_{k+1}H_k.$$

注意到

$$r_0 = \alpha v_1.$$

若记 $d_k = \alpha e_1$, 其中 e_1 是 k 阶单位矩阵的第一列, 则上述最小值问题等价于求 k 维向量 y_k 使得

$$\|V_{k+1}(d_k - H_k y_k)\|_2 = \min$$

若 v_1, v_2, \dots, v_{k+1} 是空间 $\kappa(A, r_0, k+1)$ 的标准正交基, 则有 $V_{k+1}^T V_{k+1} = I$, 于是上式即为求一个 k 维向量 y_k 满足

$$\|d_k - H_k y_k\|_2 = \min.$$

这个系数矩阵为上Hessenberg矩阵, 其相应的最小二乘问题很容易求得.

正交基 v_1, v_2, \dots, v_{k+1} 和系数阵 H_k 的元素 h_{ij} 可以用Gram-Schmidt正交化逐步求得:

$$v_1 = \frac{r_0}{\|r_0\|_2}, h_{ij} = v_i^T A v_j, i = 1, 2, \dots, j,$$

$$\tilde{v}_{j+1} = A v_j - \sum_{i=1}^j h_{ij} v_i,$$

$$h_{j+1,j} = \|\tilde{v}_{j+1}\|, v_{j+1} = \frac{\tilde{v}_{j+1}}{h_{j+1,j}}.$$

这个迭代称作Arnoldi迭代.

将

$$x_k = x_0 + V_k y_k$$

作为线性方程组的近似解. 这一方法称为广义极小剩余法(GMRES).

当 k 很大时, 由于整个计算过程需要保存所有的向量 v_1, v_2, \dots, v_{k+1} , 因此需要占用大量的存储单元, 以至于使得所处理问题的规模受到很大的限制. 为了克服(GMRES)的这个缺点, 通常使用时, 先选择一个适当的正整数 m , 计算到 $k = m$ 时, 就去求 x_m ; 然后在以 x_m 为初始向量重新开始; 这样循环直到求出满足精度的近似解. 这种循环的GMRES, 习惯上称为GMRES(m).

GMRES(m)算法

- ① 输入 A, b, x_0, m , 以及精度要求 ϵ ;
- ② $r_0 = b - Ax_0, v_1 = \frac{r_0}{\|r_0\|_2}, k := 1$;
- ③ $h_{ik} = v_i^T Av_k, i = 1, 2, \dots, k,$
 $\tilde{v}_{k+1} = Av_k - (h_{1k}v_1 + \dots + h_{kk}v_k)$
 $h_{k+1,k} = \|\tilde{v}_{k+1}\|_2$;
- ④ 若 $h_{k+1,k} < \epsilon$ 或者 $k = m$, 则转步(5); 否则 $v_{k+1} = \frac{\tilde{v}_{k+1}}{h_{k+1,k}},$
 $k := k + 1$, 转步(3);
- ⑤ 求解最小二乘问题

$$\|H_k y_k - d_k\|_2 = \min$$

并计算 $x_k = x_0 + V_k y_k$.

- ⑥ 若 $\|Ax_k - b\| < \epsilon$, 则输出 x_k , 结束; 否则 $x_0 := x_m$, 转步(2).

目前, 这一方法是求解大型稀疏非对称线性方程组最有效的方法之一. 若 $\frac{1}{2}(A + A^T)$ 是正定的, 对任意 m , GMRES(m)产生的向量序列是收敛的.